北京大學

第二讲
概率基础

机器学习概论

邓志鸿

2025年9月15日星期一

内容

- 基本概念
- 贝叶斯公式
- 主要概率分布
  - 离散型概率分布
  - 连续型概率分布
- 指数分布族
- 概率分布度量
  - 不确定性
  - 差异性

概率

- 概率是度量随机事件发生的可能性的方法
- 概率论是研究随机现象规律的一门学科
- 基本概念
  - 随机试验：E
    - ✓可重复性：试验在相同条件下可重复进行
    - ✓可知性：每次试验的可能结果不止一个，并且事先能明确试验所有可能的结果
    - ✓不确定性：进行一次试验之前不能确定哪一个结果会出现，但必然会出现结果中的一个
  - 样本空间：Ω
    - ✓随机试验E的所有可能出现的基本结果组成的集合
  - 事件：A
    - ✓满足某些条件的样本点所组成的集合，是样本空间的子集，即$A \subseteq \Omega$

实际场景

掷骰子

基本概念

- E是一随机试验， Ω是其上的样本空间，对于E上的事件A，定义函数$P(\quad)$。称$P(\quad)$为随机试验E上的概率，如果函数$P(\quad)$满足以下三个条件
  - 非负性： $\forall A \subseteq \Omega$，$0 \le P(A) \le 1$
  - 规范性：$P(\Omega) = 1$
  - 可列可加性：对可列事件$A_1, A_2, \ldots$，如果其中任意两个事件互不相容（即$A_i \cap A_j = \emptyset, i \neq j$），有

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

基本性质

- $P(\emptyset)=0$
- 两两互不相容的N个事件$A_1,A_2,\dots,A_N$，有$P(\cup_{n=1}^{N}A_n)=\sum_{n=1}^{N}P(A_n)$
- $\forall A\subseteq\Omega$，记$A^c=\Omega-A$，有$P(A^c)=1-P(A)$
- 当$A\subseteq B$，有$P(B-A)=P(B)-P(A)$
- 任意A,B，有$P(A\cap B)=P(B)-P(B-A)$，简记$P(A\cap B)$为$P(A,B)$或$P(AB)$
- 任意A,B，有$P(A\cup B)=P(A)+P(B)-P(A\cap B)$
- 任意$A_1,A_2,\dots,A_N$，有

$$P\left(\bigcup_{i=1}^{N}A_i\right)=\sum_{i}P(A_i)-\sum_{i<j}P(A_i,A_j)+\sum_{i<j<k}P(A_i,A_j,A_k)+\cdots+(-1)^{N+1}P(A_i,A_j,\dots,A_N)$$

条件概率

- 给定事件A，事件B发生的条件概率定义如下
  - 注意：$P(A)>0$，否则没定义 $$P(B|A) \triangleq \frac{P(A,B)}{P(A)}$$
- 联合概率

$$P(A,B)=P(A)P(B|A)=P(B)P(A|B)$$

- 全概率公式
  - $A_1,A_2,\dots,A_N$两两互不相容，且$\cup_{n=1}^{N} A_n=\Omega$

$$P(B)=\sum_{n=1}^{N} P(A_n,B)=\sum_{n=1}^{N} P(A_n)P(B|A_n)$$

- 乘法公式

$$P(A_1,A_2,\dots,A_N)=P(A_1)P(A_2|A_1)\cdots P(A_N|A_1,A_2,\dots,A_{N-1})$$

独立

- 给定事件A和B，称A和B是独立的，如果
  - $P(A,B)=P(A)P(B)$
- 称事件$A_1,A_2,\dots,A_N$是独立的，如果对任意的$A_{s_1},A_{s_2},\dots,A_{s_k}(k\le N)$，有
  - $P\left(A_{s_1},A_{s_2},\dots,A_{s_k}\right)=\prod_{i=1}^{k}P\left(A_{s_i}\right)$
- 给定事件C，称事件A和B在事件C下是条件独立的，如果
  - $P(A,B|C)=P(A|C)P(B|C)$
- 给定事件C，称事件$A_1,A_2,\dots,A_N$在事件C下是条件独立的，如果对任意的$A_{s_1},A_{s_2},\dots,A_{s_k}(k\le N)$，有
  - $P\left(A_{s_1},A_{s_2},\dots,A_{s_k}|C\right)=\prod_{i=1}^{k}P\left(A_{s_i}|C\right)$

ITML 随机变量

- 在实际应用中，人们常常对结果的某些函数更感兴趣，而不是对于试验结果本身。
  - 如在掷骰子时，以两次骰子的点数和定输赢。这时，我们关心两次结果的和，而非具体的试验结果。比如，我们关系点数和是否为9，而并不关心其实际结果是否是（3，6）、（4，5）、（5，4）、（6，3）。
- 这些定义在样本空间上的实值函数（我们关注的内容），称为随机变量 (random variable)
  - X表示随机变量
  - $\mathcal{X}$表示随机变量的取值空间，也称样本空间
- 两类随机变量
  - 离散随机变量 (discrete random variables)
  - 连续随机变量 (discrete random variables)

离散随机变量

- 离散随机变量
  - 样本空间$\mathcal{X}$包含有限个或可数个元素
- 概率质量函数 (probability mass function, pmf)
  - $p(x) \triangleq P(X = x)$
  - 性质
    - ✓ $0 \leq p(x) \leq 1$
    - ✓ $\sum_{x \in \mathcal{X}} p(x) = 1$
- 以掷骰子（假定均匀）为例
  - X：掷两次骰子的点数之和
  - $\mathcal{X} = \{2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12\}$
  - $p(9) = P(X = 9) = P\big((3,6), (4,5), (5,4), (6,3)\big) = \frac{4}{36}$

连续随机变量

- 连续随机变量 (discrete random variables)
  - 样本空间$\mathcal{X}=\mathbb{R}$，即$x\in\mathbb{R}$
- 累积分布函数 (cumulative distribution function, cdf)
  - $P(x)\triangleq P(X\leq x)$：单调上升
  - 事件$A=(X\leq a),B=(X\leq b),C=(b<X\leq a)$： $P(A)=P(B)+P(C)$
- 概率密度函数 (probability density function, pdf)
  - $p(x)\triangleq\frac{d}{dx}P(x)$
  - 例子

$$P(a)=P(A)=\int_{-\infty}^{a}p(x)dx \qquad P(C)=\int_{b}^{a}p(x)dx$$

联合概率分布

- 之前关注一个随机变量上的概率分布
- 联合概率分布简称联合分布，是两个及以上随机变量组成的随机向量的概率分布
- 根据随机变量的不同，联合概率分布的表示形式也不同。
  - 对于离散型随机变量，联合概率分布可以以列表的形式表示，也可以以函数的形式表示
  - 对于连续型随机变量，联合概率分布通过一非负函数的积分表示
- 主要类型
  - 二元联合分布
  - 多元联合分布

二元离散随机变量联合分布

- X和Y是两个离散随机变量
- 概率质量函数
  - $p(x,y) \triangleq P(X=x,Y=y)$
- 边缘分布 (marginal distribution)
  - $p(x) \triangleq P(X=x) \triangleq \sum_y P(X=x,Y=y)$
  - $p(y) \triangleq P(Y=y) \triangleq \sum_x P(X=x,Y=y)$
- 条件概率分布
  - $p(x|y) \triangleq P(X=x|Y=y) \triangleq \frac{P(X=x,Y=y)}{P(Y=y)}$
  - $p(x,y) = p(x|y)p(y) = p(y|x)p(x)$

$P(X,Y)$	$Y=0$	$Y=1$	$Y=2$
$X=0$	0.1	0.15	0.05
$X=1$	0.25	0.25	0.2

二元离散联合概率示例

多元离散随机变量联合分布

- N个离散随机变量$X_n (1 \le n \le N)$
- 概率质量函数
  - $p(x_1, \dots, x_N) \triangleq P(X_1 = x_1, \dots, X_N = x_N)$
- 边缘分布 (marginal distribution)
  - $p(x_1) \triangleq P(X_1 = x_1) \triangleq \sum_{x_2,\dots x_N} P(X_1 = x_1, X_2 = x_2, \dots, X_N = x_N)$
  - $p(x_1, x_2) \triangleq P(X_1 = x_1, X_2 = x_2) \triangleq \sum_{x_3,\dots x_N} P(X_1 = x_1, X_2 = x_2, X_3 = x_3, \dots, X_N = x_N)$
  - …
- 概率的链式法则 (the chain rule of probability)
  - $\boldsymbol{x}_{1:n} \triangleq x_1, \dots, x_n$
  - $p(x_1, \dots, x_N) = p(x_1)p(x_2|x_1)p(x_3|x_1, x_2) \cdots p(x_N|\boldsymbol{x}_{1:N-1})$

二元连续随机变量联合分布

- X，Y是两个连续随机变量
- 累积分布函数 (cumulative distribution function, cdf)
  - $P(a,b) \triangleq P(X \le a, Y \le b) = \int_{-\infty}^{a}\int_{-\infty}^{b} p(x,y)dxdv$
  - $p(x,y)$是联合概率密度函数
- 边缘分布 (marginal distribution)
  - $P(x) \triangleq P(X \le x) \triangleq \int_{-\infty}^{x}\int_{-\infty}^{\infty} p(u,y)dydu$
  - $P(y) \triangleq P(Y \le y) \triangleq \int_{-\infty}^{y}\int_{-\infty}^{\infty} p(x,v)dxdv$
- 边缘分布的概率密度函数
  - $p(x) \triangleq \int_{-\infty}^{\infty} p(x,y)dy$
  - $p(y) \triangleq \int_{-\infty}^{\infty} p(x,y)dx$

多元连续随机变量联合分布

- N个连续随机变量$X_n(1 \leq n \leq N)$
- 累积分布函数 (cumulative distribution function, cdf)
  - $P(a_1, \dots, a_N) \triangleq P(X_1 \leq a_1, \dots, X_N \leq a_N) = \int_{-\infty}^{a_1} \cdots \int_{-\infty}^{a_N} p(x_1, \dots, x_N) dx_1 \cdots dx_N$
  - $p(x_1, \dots, x_N)$是联合概率密度函数
- 边缘分布 (marginal distribution)
  - $P(x_i) \triangleq P(X_i \leq x_i) \triangleq \int_{-\infty}^{x_i} \iint_{j \neq i}^{\infty} p(x_1, \dots, x_{i-1}, u, x_{i+1}, \dots, x_N)\, dx_1 \cdots dx_{i-1} dx_{i+1} \cdots dx_N du$
- 边缘分布的概率密度函数
  - $p(x_i) \triangleq \iint_{j \neq i}^{\infty} p(x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_N)\, dx_1 \cdots dx_{i-1} dx_{i+1} \cdots dx_N$

ITML

随机向量概率分布

- 随机向量$\boldsymbol{X} = [X_1, \dots, X_D]^{\mathrm{T}}$，其中$X_n$是离散随机变量， $\boldsymbol{x} = [x_1, \dots, x_D]^{\mathrm{T}}$
- 概率质量函数
  - $p(\boldsymbol{x}) = p\left(\begin{bmatrix} x_1 \\ \vdots \\ x_D \end{bmatrix}\right) \triangleq P(\boldsymbol{X} = \boldsymbol{x}) = P(X_1 = x_1, \dots, X_N = x_D)$
- 边缘分布 (marginal distribution)
  - $p(x_1) \triangleq P(X_1 = x_1) \triangleq \sum_{x_2, \dots x_D} P(X_1 = x_1, X_2 = x_2, \dots, X_D = x_D)$
  - $p(x_1, x_2) \triangleq P(X_1 = x_1, X_2 = x_2) \triangleq \sum_{x_3, \dots x_D} P(X_1 = x_1, X_2 = x_2, X_3 = x_3, \dots, X_D = x_D)$
  - …

随机向量概率分布

- 随机向量$\boldsymbol{X} = [X_1, \ldots, X_D]^{\mathrm{T}}$，其中$X_D$是连续随机变量， $\boldsymbol{x} = [x_1, \ldots, x_D]^{\mathrm{T}}$
  - 累积分布函数

$$P\left(\begin{bmatrix} a_1 \\ \vdots \\ a_D \end{bmatrix}\right) \triangleq P\left(\boldsymbol{X} \leq \begin{bmatrix} a_1 \\ \vdots \\ a_D \end{bmatrix}\right) = P(X_1 \leq a_1, \ldots, X_N \leq a_D) = \int_{-\infty}^{a_1} \cdots \int_{-\infty}^{a_D} p(\boldsymbol{x}) dx_1 \cdots dx_D$$

✓$p(\boldsymbol{x}) = p(x_1, \ldots, x_D)$是概率密度函数

  - 边缘分布

$$P(y_i) \triangleq P(X_i \leq y_i) \triangleq \int_{-\infty}^{y_i} \iint_{j \neq i}^{\infty} p(\boldsymbol{x})\, dx_1 \cdots dx_{i-1} dx_{i+1} \cdots dx_D dx_i$$

✓边缘分布的概率密度函数

$$p(x_i) \triangleq \iint_{j \neq i}^{\infty} p(\boldsymbol{x})\, dx_1 \cdots dx_{i-1} dx_{i+1} \cdots dx_D$$

独立和条件独立

- 给定随机变量X和Y，称X和Y是独立的，记$X \perp Y$，如果

$$X \perp Y \Leftrightarrow P(X,Y) = P(X)P(Y) \Leftrightarrow p(x,y) = p(x)\,p(y)$$

- 给定多个随机变量$x_1, \dots, x_N$，称其是独立的，如果

$p(\quad)$ 为概率质量函数（离散）或概率密度函数（连续）

$$P(X_1, \dots, X_N) = \prod_{n=1}^{N} P(X_n) \Leftrightarrow p(x_1, \dots, x_N) = \prod_{n=1}^{N} p(x_n)$$

- 给定随机变量Z，称随机变量X和Y在Z下是条件独立，如果

$$X \perp Y|Z \Leftrightarrow P(X,Y|Z) = P(X|Z)P(Y|Z) \Leftrightarrow p(x,y|z) = p(x|z)\,p(y|z)$$

–推广到多个随机变量 $P(X_1, \dots, X_N|Z) = \prod_{n=1}^{N} P(X_n|Z)$

概率分布统计量：均值

- 给定随机变量X，其概率分布为$P(X)$，则其均值（也称期望值）定义如下
  - X是离散随机变量 $\mathbb{E}[X] \triangleq \sum_{x\in\mathcal{X}} xp(x)$
  - X是连续随机变量 $\mathbb{E}[X] \triangleq \int xp(x)dx$
- 性质
  - $\mathbb{E}[aX+b] = a\mathbb{E}[X]+b$，其中$a$和$b$是常量
  - $\mathbb{E}\left[\sum_{n=1}^{N} X_n\right] = \sum_{n=1}^{N} \mathbb{E}[X_n]$
  - 如果$x_1,\dots,x_N$独立，则 $\mathbb{E}\left[\prod_{n=1}^{N} X_n\right] = \prod_{n=1}^{N} \mathbb{E}[X_n]$

概率分布统计量：方差

- 给定随机变量X，其概率分布为$P(X)$，则其方差σ^2定义如下

$$\sigma^2 = \mathbb{V}[X] \triangleq \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \Rightarrow \mathbb{E}[X^2] = \mathbb{V}[X] + (\mathbb{E}[X])^2$$

  – 标准差 (standard deviation)

$$\mathrm{std}[X] \triangleq \sqrt{\mathbb{V}[X]} = \sigma$$

- 性质

  – $\mathbb{V}[aX + b] = a^2\mathbb{V}[X]$，其中$a$和$b$是常量

  – 如果$x_1, \ldots, x_N$独立，则

$$\mathbb{V}\left[\sum_{n=1}^{N} X_n\right] = \sum_{n=1}^{N} \mathbb{V}[X_n] \qquad \mathbb{V}\left[\prod_{n=1}^{N} X_n\right] = \prod_{n=1}^{N}(\mathbb{V}[X_n] + (\mathbb{E}[X_n])^2) - \prod_{n=1}^{N}(\mathbb{E}[X_n])^2$$

概率分布统计量：众数

- 给定概率分布，其概率密度函数（连续随机变量）或概率质量函数（离散随机变量）的最大值称为众数 (mode)

$$x^* = \underset{x}{\operatorname{argmax}}\, p(x)$$

  – 概率分布的众数可以只有一个，也可以有多个。对于有多个众数的分布，也被称为多峰分布（multimodal distribution）

  – 一般而言，概率分布的众数不是一个好的统计量

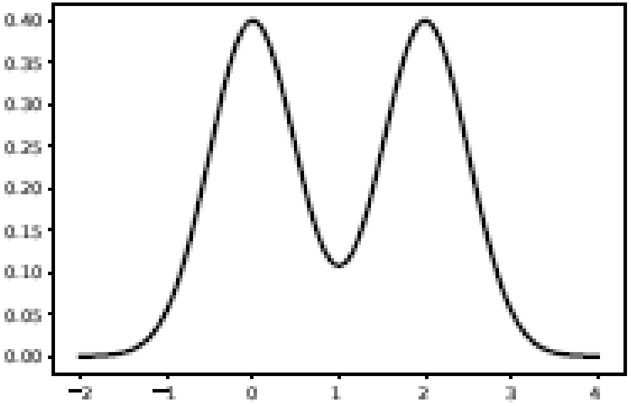

随机向量统计量：期望与方差

- 随机向量$\boldsymbol{X}=[X_1,\dots,X_N]^{\mathrm{T}}$，其中$X_i$是随机变量，$\boldsymbol{x}=[x_1,\dots,x_N]^{\mathrm{T}}$
  - 均值

$$\mathbb{E}[\boldsymbol{X}] \triangleq \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_N] \end{bmatrix}$$

$$\mathbb{E}[X_i]=\sum_{x_1,\dots,x_N} x_i p(\boldsymbol{x})=\sum_{x_i} x_i p(x_i)$$

$$\mathbb{E}[X_i]=\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} x_i p(\boldsymbol{x}) dx_1\cdots dx_N=\int_{-\infty}^{\infty} x_i p(x_i) dx_i$$

  - 协方差矩阵

$$\mathrm{Cov}[\boldsymbol{X}] \triangleq \mathbb{E}[(\boldsymbol{X}-\mathbb{E}[\boldsymbol{X}])(\boldsymbol{X}-\mathbb{E}[\boldsymbol{X}])^{\mathrm{T}}]$$

$$=\begin{bmatrix} \mathrm{Cov}[X_1,X_1] & \mathrm{Cov}[X_1,X_2] & \cdots & \mathrm{Cov}[X_1,X_D] \\ \mathrm{Cov}[X_2,X_1] & \mathrm{Cov}[X_2,X_2] & \cdots & \mathrm{Cov}[X_2,X_D] \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}[X_D,X_1] & \mathrm{Cov}[X_D,X_2] & \cdots & \mathrm{Cov}[X_D,X_D] \end{bmatrix}$$

$$\mathrm{Cov}[X_i,X_j] \triangleq \mathbb{E}[(X_i-\mathbb{E}[X_i])(X_j-\mathbb{E}[X_j])]=\mathbb{E}[X_iX_j]-\mathbb{E}[X_i]\mathbb{E}[X_j]$$

$$\mathbb{E}[X_iX_j]=\sum_{x_i,x_j} x_i x_j p(x_i,x_j) \qquad \mathbb{E}[X_iX_j]=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} x_i x_j p(x_i,x_j) dx_i dx_j$$

协方差$\mathrm{Cov}[X_i, X_j]$度量随机变量X_i和X_j的线性相关程度

$$\mathrm{Cov}[X_i, X_j] \triangleq \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i]\mathbb{E}[X_j]$$

$$\mathbb{V}[X_i] = \mathrm{Cov}[X_i, X_i]$$

$$\begin{aligned}\mathrm{Cov}[\boldsymbol{X}] &\triangleq \mathbb{E}[(\boldsymbol{X} - \mathbb{E}[\boldsymbol{X}])\,(\boldsymbol{X} - \mathbb{E}[\boldsymbol{X}])^{\mathrm{T}}] \\ &= \mathbb{E}[(\boldsymbol{X} - \boldsymbol{\mu})\,(\boldsymbol{X} - \boldsymbol{\mu})^{\mathrm{T}}] \\ &= \mathbb{E}[\boldsymbol{X}\boldsymbol{X}^{\mathrm{T}}] - \boldsymbol{\mu}\boldsymbol{\mu}^{\mathrm{T}}\end{aligned}$$

$$-\infty < \mathrm{Cov}[X_i, X_j] < \infty$$

$$\mathrm{Cov}[\mathbf{A}\boldsymbol{X} + \boldsymbol{b}] = \mathbf{A}\mathrm{Cov}[\boldsymbol{X}]\mathbf{A}^{\mathrm{T}}$$

随机向量统计量：相关系数

随机变量X_i和X_j的相关系数 (correlation coefficient) ρ_{ij}

$$\rho_{ij} = \mathrm{Corr}[X_i, X_j] \triangleq \frac{\mathrm{Cov}[X_i, X_j]}{\sqrt{\mathbb{V}[X_i]\mathbb{V}[X_j]}} \Rightarrow \mathrm{Cov}[X_i, X_j] = \rho_{ij}\sigma_i\sigma_j \qquad -1 \le \rho_{ij} \le 1$$

$$\mathbb{V}[X_i] = \mathrm{Cov}[X_i, X_i] \triangleq \sigma_i^2$$

$$\mathrm{Corr}[\boldsymbol{X}] = \begin{bmatrix} 1 & \frac{\mathrm{Cov}[X_1, X_2]}{\sigma_1\sigma_2} & \cdots & \frac{\mathrm{Cov}[X_1, X_D]}{\sigma_1\sigma_D} \\ \frac{\mathrm{Cov}[X_2, X_1]}{\sigma_2\sigma_1} & 1 & \cdots & \frac{\mathrm{Cov}[X_2, X_D]}{\sigma_2\sigma_D} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\mathrm{Cov}[X_D, X_1]}{\sigma_D\sigma_1} & \frac{\mathrm{Cov}[X_D, X_2]}{\sigma_D\sigma_2} & \cdots & 1 \end{bmatrix}$$

不相关不代表独立

如果随机变量X_i和X_j独立，则 $\rho_{ij}=0$。这时也称X_i和X_j不相关

注意：随机变量X_i和X_j不相关，推不出X_i和X_j独立

例如：X_i是区间$[-1,1]$上的均匀分布，即$X_i \sim U(-1,1)$， $X_j = X_i^2$。
显然， X_i和X_j不独立

$$
\begin{aligned}
\mathrm{Cov}[X_i, X_j] &= \mathbb{E}[X_i X_j] - \mathbb{E}[X_i]\mathbb{E}[X_j] \\
&= \mathbb{E}[X_i^3] - \mathbb{E}[X_i]\mathbb{E}[X_i^2] \\
&= 0 - 0\mathbb{E}[X_i^2] = 0
\end{aligned}
$$

随机向量统计量：相关系数

相关不代表因果

辛普森悖论 (Simpson's paradox)

学科	男生申请	男生录取	男生录取率
理科	1000	490	49%
文科	200	10	5%
总计	1200	500	42%

学科	女生申请	女生录取	女生录取率
理科	200	140	70%
文科	1000	100	10%
总计	1200	240	20%

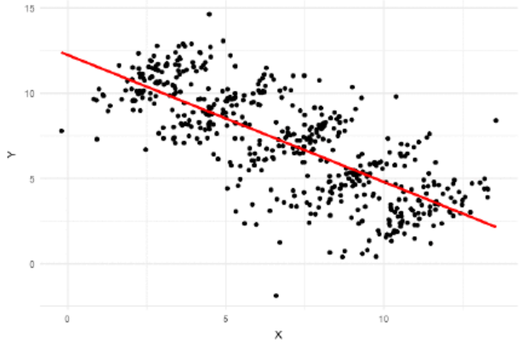

全局

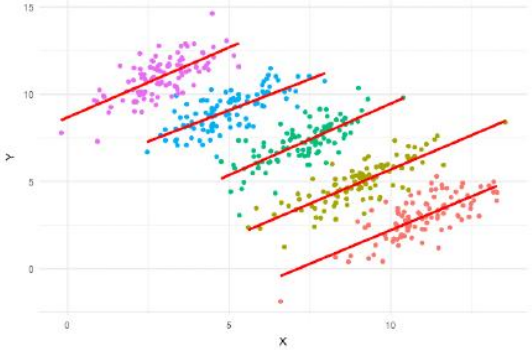

局部分组

- 全期望法则 (law of total expectation)
  - $\mathbb{E}[X] = \mathbb{E}\big[\mathbb{E}[X|Y]\big]$
- 证明

$$\mathbb{E}\big[\mathbb{E}[X|Y]\big] = \mathbb{E}\left[\sum_x xP(X = x|Y)\right]$$

$$= \sum_y \left(\sum_x xP(X = x|Y)\right) P(Y = y)$$

$$= \sum_x \left(\sum_y xP(X = x|Y)P(Y = y)\right)$$

$$= \sum_x \left(\sum_y xP(X = x, Y = y)\right) = \sum_x (xP(X = x)) = \mathbb{E}[X]$$

概率分布的统计量：条件方差

- 全方差法则 (law of total variance)
  - $\mathbb{V}[X] = \mathbb{E}\left[\mathbb{V}[X|Y]\right] + \mathbb{V}\left[\mathbb{E}[X|Y]\right]$
- 证明

$$\mu_{X|Y} \triangleq \mathbb{E}[X|Y]$$

$$s_{X|Y} \triangleq \mathbb{E}[X^2|Y]$$

$$\sigma^2_{X|Y} \triangleq \mathbb{V}[X|Y] = s_{X|Y} - \mu^2_{X|Y}$$

$$\begin{aligned}
\mathbb{V}[X] &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \\
&= \mathbb{E}\left[s_{X|Y}\right] - \left(\mathbb{E}\left[\mu_{X|Y}\right]\right)^2 \\
&= \mathbb{E}\left[\sigma^2_{X|Y} + \mu^2_{X|Y}\right] - \left(\mathbb{E}\left[\mu_{X|Y}\right]\right)^2 \\
&= \mathbb{E}\left[\sigma^2_{X|Y}\right] + \mathbb{E}\left[\mu^2_{X|Y}\right] - \left(\mathbb{E}\left[\mu_{X|Y}\right]\right)^2 \\
&= \mathbb{E}\left[\sigma^2_{X|Y}\right] + \mathbb{V}\left[\mu_{X|Y}\right] = \mathbb{E}\left[\mathbb{V}[X|Y]\right] + \mathbb{V}\left[\mathbb{E}[X|Y]\right]
\end{aligned}$$

贝叶斯公式

- Bayes' rule

$$P(H=h|X=x)=\frac{P(X=x|H=h)\times P(H=h)}{P(X=x)}$$

  - 简写

似然

likelihood

先验分布

prior distribution

$$\underbrace{p(h|x)}_{\text{后验分布 posterior distribution}}=\frac{p(x|h)\times p(h)}{p(x)}$$

后验分布

posterior distribution

边缘似然

Marginal likelihood

给定观测数据，通过贝叶斯公式修改所关注随机变量分布的过程称为贝叶斯推断或推理（bayesian inference），或后验推断或推理（posterior inference）,或概率推断或推理（probabilistic inference）

  - 边缘似然
    - ✓ H是离散随机变量 $p(x)=\sum_{h'}p(x|h')\times p(h')$
    - ✓ H是连续随机变量 $p(x)=\int p(x|h')\times p(h')\,dh'$

贝叶斯公式：医疗诊断

- 路人甲有些症状，想通过相关测试来确定自己是否感染了疾病D
- 约定
  - H表示人是否感染的随机变量。 $H=1$表示感染了， $H=0$表示没有感染
  - X表示检查结果的随机变量。 $X=1$代表检测结果为阳性， $X=0$代表检测结果为阴性
- 目标
  - 在已知检测结果的条件下，计算是否感染的概率，即计算$P(H=h|X=x)$
- 检测可靠性相关指标（通过统计可以获取）
  - 敏感性 (sensitivity, true positive rate, TPR)： $P(X=1|H=1)$
  - 假阴性率 (false negative rate, FNR)，又称漏诊率： $P(X=0|H=1)$
  - 特异性(specificity, true negative rate, TNR)： $P(X=0|H=0)$
  - 假阳性率 (false positive rate, FPR)，又称误诊率： $P(X=1|H=0)$
  - 流行率 (prevalence rate), 又称患病率： $P(H=1)$

贝叶斯公式：医疗诊断

$$P(H=1)=10\%$$

		检测结果 (X)	
		0	1
真实情况 (H)	0	0.95 (TNR)	0.05 (FPR)
	1	0.1 (FNR)	0.9 (TPR)

检测指标统计表

$$P(H=1|X=1)=\frac{P(X=1|H=1)P(H=1)}{P(X=1)}=\frac{P(X=1|H=1)P(H=1)}{P(X=1|H=0)P(H=0)+P(X=1|H=1)P(H=1)}$$

$$=\frac{0.9\times 0.1}{0.05\times(1-0.1)+0.9\times 0.1}=0.667$$

$$P(H=1|X=0)=\frac{P(X=0|H=1)P(H=1)}{P(X=0)}=\frac{P(X=0|H=1)P(H=1)}{P(X=0|H=0)P(H=0)+P(X=0|H=1)P(H=1)}$$

$$=0.012$$

贝叶斯公式：医疗诊断

$P(H=1)=2\%$

		检测结果 (X)	
		0	1
真实情况 (H)	0	0.95 (TNR)	0.05 (FPR)
	1	0.1 (FNR)	0.9 (TPR)

检测指标统计表

$$P(H=1|X=1)=\frac{P(X=1|H=1)P(H=1)}{P(X=1)}=\frac{P(X=1|H=1)P(H=1)}{P(X=1|H=0)P(H=0)+P(X=1|H=1)P(H=1)}$$

$$=\frac{0.9\times 0.02}{0.05\times(1-0.02)+0.9\times 0.02}=0.269$$

$$P(H=1|X=0)=\frac{P(X=0|H=1)P(H=1)}{P(X=0)}=\frac{P(X=0|H=1)P(H=1)}{P(X=0|H=0)P(H=0)+P(X=0|H=1)P(H=1)}$$

$$=0.002$$

贝叶斯公式：医疗诊断

		检测结果 (X)	
		0	1
真实情况 (H)	0	0.95 (TNR)	0.05 (FPR)
	1	0.1 (FNR)	0.9 (TPR)

$P(H=1)=10\%$

$P(H=1)=2\%$

$P(H=1|X=1)=0.667$　　$P(H=1|X=0)=0.012$　　$P(H=1|X=1)=0.269$　　$P(H=1|X=0)=0.002$

假定统计样本为10000人

感染人数为10000X0.1=1000人

感染的人中有0.9X1000=900人检测呈阳性

未感染的9000人中有0.05X9000=450人检测呈阳性

故检测呈阳性的人数为900+450=1350

故 $P(H=1|X=1)=\frac{900}{1350}=0.667$

感染人数为10000X0.02=200人

感染的人中有0.9X200=180人检测呈阳性

未感染的9800人中有0.05X9800=490人检测呈阳性

故检测呈阳性的人数为180+490=670

故 $P(H=1|X=1)=\frac{180}{670}=0.269$

贝叶斯公式：三门问题

- 蒙提霍尔问题 (The Monty Hall Problem)
- 游戏描述
  - 有三扇门，其中一扇门后面有一辆豪车。你可以有两次选门的机会，如果选中的门后面有豪车，则豪车归你；否则，空手而归
- 游戏过程
  - 你先选一扇门
  - 然后主办方打开剩下的两扇门中的一扇门，但这个门后面没有豪车
  - 问题：第二次选择时，你是保留上次选择的门不变，还是选另一扇仍然关上的门

1号门

第一次选择的门

2号门

没有

豪车

3号门

是保持不变呢？

还是选择改变？

这是一个问题！

贝叶斯公式：三门问题

- 假定
  - 你选择了1号门（后面是否有豪车不清楚）
  - 主办方打开了2号门，后面没有豪车
  - 你可以做第二次选择
    - ✓继续选择1号门
    - ✓改为选择3号门

这会是一个问题吗?

是吗?

不是吗?

- 约定
  - H表示后面有豪车的门标号的随机变量。 $H = i$表示第i扇门后有豪车。在无任何信息的情况下，各门后有豪车的概率相同（先验概率），即
    - ✓$P(H = 1) = P(H = 2)P(H = 3) = 1/3$
  - X表示主办方选择的门标号的随机变量。$X = i$表示主办方选择第i扇门
- 任务
  - 根据已知信息$X = 2$（主办方打开2号门），求解后验概率$P(H|X = 2)$

贝叶斯公式：三门问题

- 在你选择1号门后，主办方选择打开哪号门的概率（注意：主办方事先知道豪车在哪个门后）
  - 如果豪车在1号门后，主办方可以随机选择打开2号门或3号门（这两门后都没有豪车）
    - ✓ $P(X=2|H=1)=P(X=3|H=1)=1/2$
  - 如果豪车在2号门后，主办方只能打开3号门
    - ✓ $P(X=2|H=2)=0;\ P(X=3|H=2)=1$
  - 如果豪车在3号门后，主办方只能打开2号门
    - ✓ $P(X=2|H=3)=1;\ P(X=3|H=3)=0$
- 已知主办方打开2号门，即X=2，利用贝叶斯公式计算如下

$$P(H=1|X=2)=\frac{P(X=2|H=1)P(H=1)}{P(X=2)}=\frac{1}{P(X=2)}\times\frac{1}{2}\times\frac{1}{3}$$

$$P(H=2|X=2)=\frac{P(X=2|H=2)P(H=2)}{P(X=2)}=\frac{1}{P(X=2)}\times 0\times\frac{1}{3}$$

$$P(H=3|X=2)=\frac{P(X=2|H=3)P(H=3)}{P(X=2)}=\frac{1}{P(X=2)}\times 1\times\frac{1}{3}$$

$$P(X=2)=\frac{1}{2}\Rightarrow\begin{cases}P(H=1|X=2)=\frac{1}{3}\\ P(H=2|X=2)=0\\ P(H=3|X=2)=\frac{2}{3}\end{cases}$$

离散型概率分布：伯努利分布

- 伯努利分布 (Bernoulli distribution）
  - 又名两点分布或0-1分布
  - 样本空间$\mathcal{X} = \{0, 1\}$，即$x \in \{0, 1\}$
    - ✓$P(X = 1) = \theta$
    - ✓$P(X = 0) = 1 - \theta$
    - ✓统一表示为

$$p(x) = P(X = x) = \theta^x (1 - \theta)^{1-x}$$

Logistic回归用到伯努利分布建模

简记 $X \sim \mathrm{Ber}(\theta)$

$$\mathbb{E}[X] = \theta$$

$$\mathbb{V}[X] = \theta(1 - \theta)$$

离散型概率分布：二项分布

- 二项分布 (binomial distribution)
  - N 次独立重复的伯努利试验，$X_n \sim \mathrm{Ber}(\theta), 1 \le n \le N$。 $x \triangleq \sum_{n=1}^{N} \mathbb{I}(x_n = 1) = \sum_{n=1}^{N} x_n$，$x \in \{0, 1, \dots, N\}$，满足以下分布

二项式系数

$$p(x) = P(X = x) = \mathrm{Bin}(x; N, \theta) \triangleq \binom{N}{x} \theta^x (1-\theta)^{N-x} \qquad \binom{N}{x} \triangleq \frac{N!}{(N-x)!\,x!}$$

简记 $X \sim \mathrm{Bin}(N, \theta)$

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{n=1}^{N} X_n\right] = \sum_{n=1}^{N} \mathbb{E}[X_n] = N\theta$$

$$\mathbb{V}[X] = \mathbb{V}\left[\sum_{n=1}^{N} X_n\right] = \sum_{n=1}^{N} \mathbb{V}[X_n] = N\theta(1-\theta)$$

二值指示函数

$$\mathbb{I}(u) = \begin{cases} 1, u = True \\ 0, u = False \end{cases}$$

  - 伯努利分布是一类特殊的二项分布（$N = 1$）

离散型概率分布：泊松分布

- 泊松分布 (Poisson distribution)
  - $x \in \{0,1,2,\dots\}$

$$p(x) = P(X=x) = \mathrm{Poi}(x;\lambda) \triangleq e^{-\lambda}\frac{\lambda^x}{x!}$$

  - 当试验次数N趋于无穷时，二项分布变成泊松分布
  - 当参数λ趋于无穷时，泊松分布变成高斯分布

$$\lim_{N\to\infty}\binom{N}{x}\theta^x(1-\theta)^{N-x}$$

$$\Big\downarrow\ \theta \triangleq \frac{\lambda}{N}$$

$$\lim_{N\to\infty}\frac{N!}{(N-x)!\,x!}\frac{\lambda^x}{N^x}\left(1-\frac{\lambda}{N}\right)^N\left(1-\frac{\lambda}{N}\right)^{-x}$$

$$\Big\downarrow$$

$$\lim_{N\to\infty}\frac{N!}{N^x(N-x)!}\frac{\lambda^x}{x!}\left(1-\frac{\lambda}{N}\right)^N\left(1-\frac{\lambda}{N}\right)^{-x}$$

$$\Big\downarrow$$

$$\frac{\lambda^x}{x!}e^{-\lambda}$$

$$\mathbb{E}[X] = \sum_{x=0}^{\infty} x e^{-\lambda}\frac{\lambda^x}{x!} = \sum_{x=1}^{\infty} e^{-\lambda}\frac{\lambda^x}{(x-1)!}$$

$$= \lambda e^{-\lambda}\sum_{x=1}^{\infty}\frac{\lambda^{x-1}}{(x-1)!} = \lambda e^{-\lambda}\sum_{x=0}^{\infty}\frac{\lambda^x}{x!} = \lambda e^{-\lambda}e^{\lambda} = \lambda$$

$$\mathbb{V}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \lambda$$

离散型概率分布：类型分布

- 类型分布 (categorical distribution)

Logistic回归用到类型分布建模

  - 又名分类分布，是伯努利分布的扩展形式
  - $x \in \{1, 2, \dots, C\}$
    - ✓ $X \sim \mathrm{Cat}(\boldsymbol{\theta})$
    - ✓ $\boldsymbol{\theta} = [\theta_1, \dots, \theta_C]^{\mathrm{T}}$, $\sum_{c=1}^{C} \theta_c = 1$
    - ✓ $p(c) = P(X = c) = \theta_c$
    - ✓统一写成

$$p(x) = P(X = x) = \mathrm{Cat}(x; \boldsymbol{\theta}) = \prod_{c=1}^{C} \theta_c^{\mathbb{I}(x=c)}$$

$$\mathbb{E}[\mathbb{I}(x = c)] = \mathbb{I}(x = c)P(x = c) + \mathbb{I}(x = c)P(x \neq c) = 1 \times \theta_c + 0 \times (1 - \theta_c) = \theta_c$$

$$\mathbb{V}[\mathbb{I}(x = c)] = \theta_c \times (1 - \theta_c)$$

离散型概率分布：多项分布

- 多项分布 (multinomial distribution)
  - N次独立重复的类型分布试验，$Y_n \sim \mathrm{Cat}(\boldsymbol{\theta}), 1 \le n \le N$。
  - $x_c \triangleq \sum_{n=1}^{N} \mathbb{I}(y_n = c)$，即$x_c \in \{0, 1, \dots, N\}$表示$N$次独立试验中$c$出现的次数。
  - 记$\boldsymbol{x} = [x_1, \dots, x_C]^{\mathrm{T}}$，则$\boldsymbol{x}$满足以下的分布

多项式系数

$$p(\boldsymbol{x}) = P(X = \boldsymbol{x}) = \mathrm{Mu}(\boldsymbol{x}; N, \theta) \triangleq \binom{N}{x_1 \dots x_C} \prod_{c=1}^{C} \theta_c^{x_c} \qquad \binom{N}{x_1 \dots x_C} \triangleq \frac{N!}{x_1!\, x_2! \dots x_C!}$$

  - 当$N = 1$时，多项分布就退化为类型分布

$$\mathbb{E}[X_c] = \mathbb{E}\left[\sum_{n=1}^{N} \mathbb{I}(y_n = c)\right] = \sum_{n=1}^{N} \mathbb{E}[\mathbb{I}(y_n = c)] = N\theta_c$$

$$\mathbb{V}[X_c] = \mathbb{V}\left[\sum_{n=1}^{N} \mathbb{I}(y_n = c)\right] = \sum_{n=1}^{N} \mathbb{V}[\mathbb{I}(y_n = c)] = N\theta_c(1 - \theta_c)$$

连续型概率分布：高斯分布

- 高斯分布 (Gaussian distribution)
  - 也称正态分布 (normal distribution)，是使用最为广泛的概率分布
  - 概率密度函数（其中，称μ为均值， σ^2为方差）

$$p(x) = \mathcal{N}(x;\mu,\sigma^2) \triangleq \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

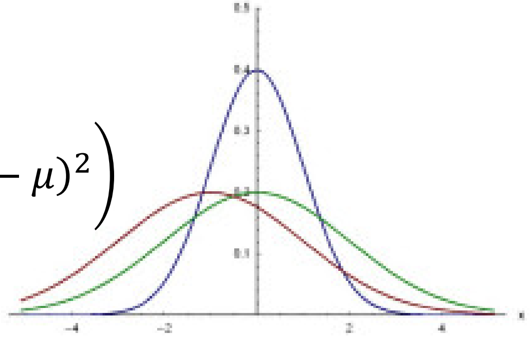

高斯分布的pdf

  - 累积分布函数

$$P(a) = \int_{-\infty}^{a} \mathcal{N}(x;\mu,\sigma^2)dx$$

$$P(a < x \le b) = \int_{a}^{b} \mathcal{N}(x;\mu,\sigma^2)dx$$

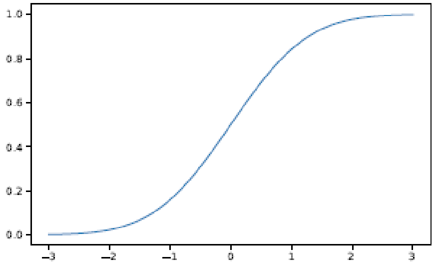

高斯分布的cdf

  - 线性回归、高斯判别分析等方法的建模基础

$$\mathbb{E}[X] = \mu \qquad \mathbb{V}[X] = \sigma^2$$

连续型概率分布：高斯分布

- 当方差趋近于零时，高斯分布趋近于在均值处无限高，两边无限窄的形状

$$\lim_{\sigma^2\to\infty} \mathcal{N}(x;\mu,\sigma^2) \longrightarrow \delta(x-\mu)$$

$$\delta(t) = \begin{cases} +\infty, t = 0 \\ 0, t \neq 0 \end{cases}$$

狄拉克delta函数(Dirac delta function)

- 狄拉克delta函数性质
  - 积分

$$\int_{-\infty}^{\infty} \delta(t)dt = 1$$

  - 筛性 (sifting property)

$$\int_{-\infty}^{\infty} f(t)\delta(x-t)dt = f(x)$$

- 拉普拉斯分布 (Laplace distribution)
  - 概率密度函数 ($b > 0$)

$$p(x) = \mathrm{Lap}(x; \mu, b) \triangleq \frac{1}{2b} \exp\left(-\frac{1}{b}|x - \mu|\right)$$

  - 累积分布函数

$$P(a) = \int_{-\infty}^{a} \mathrm{Lap}(x; \mu, b) dx$$

  - 拉普拉斯分布适合对有异常点的数据建模，是Lasso线性回归的建模基础

$$\mathbb{E}[X] = \mu \qquad \mathbb{V}[X] = 2b^2$$

连续型概率分布：Gamma分布

- Gamma分布 (Gamma distribution)
  - 定义在正实值随机变量上的覆盖面较广的概率分布， $x \in \mathbb{R}^+$
  - 概率密度函数 $(a > 0, b > 0)$

$$p(x) = \mathrm{Ga}(x; a, b) \triangleq \frac{b^a}{\Gamma(a)} x^{a-1} e^{-xb}$$

$$\mathbb{E}[X] = \frac{a}{b} \qquad \mathbb{V}[X] = \frac{a}{b^2}$$

Gamma函数 (Gamma function)

$$\Gamma(a) = \int_0^\infty x^{a-1} e^{-x} dx$$

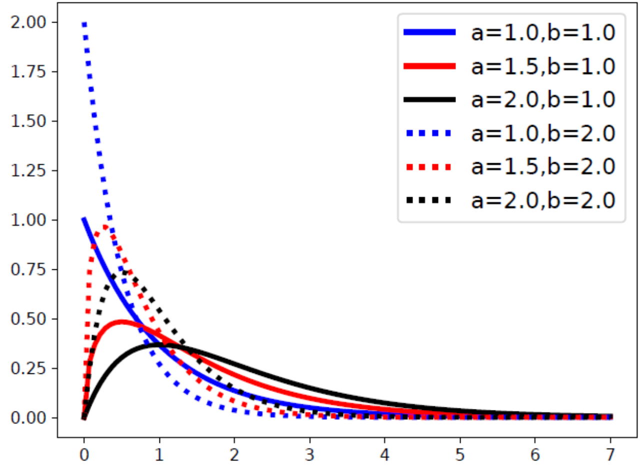

- 特殊形式
  - 指数分布 (exponential distribution)

$$p(x) = \mathrm{Ga}(x; 1, \lambda) = \lambda e^{-\lambda x}$$

  - 卡方分布 (Chi-squared distribution)

$$p(x) = \mathrm{Ga}\left(x; \frac{v}{2}, \frac{1}{2}\right)$$

- 经验分布 (empirical distribution)
  - 给定数据集$\mathcal{D}=\{x_1,\dots,x_N\}$，$x_n \sim p(x)(x\in\mathbb{R})$，可以通过以下函数近似概率密度函数$p(x)$，

$$\hat{p}_{\mathcal{D}}(x)=\frac{1}{N}\sum_{n=1}^{N}\delta(x-x_n)$$

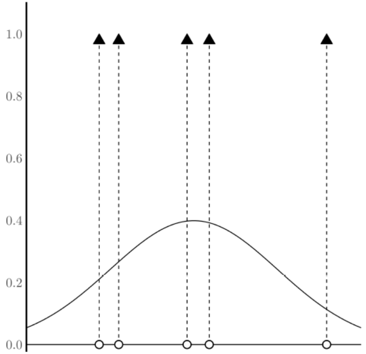

概率密度函数

    ✓以上称为数据集$\mathcal{D}$上的经验分布
  - 经验分布对应的累积分布函数如下

$$\hat{P}_{\mathcal{D}}(x)=\frac{1}{N}\sum_{n=1}^{N}\mathbb{I}(x_n\le x)$$

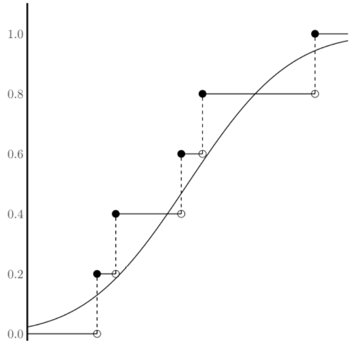

累积分布函数

  - 上述公式可以很自然推广到多元（维）情况

    ✓即，$\boldsymbol{x}\in\mathbb{R}^D$

多元高斯分布

- 多元高斯分布 (multivariate Gaussian distribution)
  - 也称多元正态分布 (multivariate normal distribution)，是使用最为广泛的概率分布
  - 概率密度函数

$$p(\boldsymbol{x}) = \mathcal{N}(\boldsymbol{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) \triangleq \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right)$$

    - $\boldsymbol{x} \in \mathbb{R}^D$,均值$\boldsymbol{\mu} \in \mathbb{R}^D$, 协方差矩阵$\boldsymbol{\Sigma}$是$D \times D$对称矩阵

随机向量 $\boldsymbol{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_D \end{bmatrix}$

$$\boldsymbol{\mu} = \mathbb{E}[\boldsymbol{X}] = \begin{bmatrix} \mathbb{E}[x_1] \\ \mathbb{E}[x_2] \\ \vdots \\ \mathbb{E}[x_D] \end{bmatrix}$$

$$\boldsymbol{\Sigma} = \mathrm{Cov}[\boldsymbol{X}] \triangleq \mathbb{E}[(\boldsymbol{X}-\mathbb{E}[\boldsymbol{X}])\,(\boldsymbol{X}-\mathbb{E}[\boldsymbol{X}])^{\mathrm{T}}] = \begin{bmatrix} \mathrm{Cov}[X_1,X_1] & \mathrm{Cov}[X_1,X_2] & \cdots & \mathrm{Cov}[X_1,X_D] \\ \mathrm{Cov}[X_2,X_1] & \mathrm{Cov}[X_2,X_2] & \cdots & \mathrm{Cov}[X_2,X_D] \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}[X_D,X_1] & \mathrm{Cov}[X_D,X_2] & \cdots & \mathrm{Cov}[X_D,X_D] \end{bmatrix}$$

$$\mathrm{Cov}[X_i,X_j] \triangleq \mathbb{E}\left[(X_i-\mathbb{E}[X_i])\,(X_j-\mathbb{E}[X_j])^{\mathrm{T}}\right] = \mathbb{E}[X_iX_j] - \mathbb{E}[X_i]\mathbb{E}[X_j]$$

多元高斯分布：边缘分布

- $\boldsymbol{x}_1 \in \mathbb{R}^D$，$\boldsymbol{x}_2 \in \mathbb{R}^K$ 是两个随机向量，$\boldsymbol{x}_1$和$\boldsymbol{x}_2$的联合分布服从以下高斯分布

$$p(\boldsymbol{x}_1, \boldsymbol{x}_2) = \mathcal{N}\left(\begin{bmatrix}\boldsymbol{x}_1 \\ \boldsymbol{x}_2\end{bmatrix}; \boldsymbol{\mu}, \boldsymbol{\Sigma}\right)$$

$$\boldsymbol{\mu} = \begin{bmatrix}\boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2\end{bmatrix} \qquad \boldsymbol{\Sigma} = \begin{bmatrix}\boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22}\end{bmatrix} \qquad \boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1} = \begin{bmatrix}\boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12} \\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22}\end{bmatrix}$$

精度矩阵 (precision matrix)

- 边缘分布

$$p(\boldsymbol{x}_1) = \mathcal{N}(\boldsymbol{x}_1; \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$$

$$p(\boldsymbol{x}_2) = \mathcal{N}(\boldsymbol{x}_2; \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$$

$\boldsymbol{\Sigma}_{11}$是$D \times D$矩阵
$\boldsymbol{\Sigma}_{12}$是$D \times K$矩阵
$\boldsymbol{\Sigma}_{21}$是$K \times D$矩阵
$\boldsymbol{\Sigma}_{22}$是$K \times K$矩阵

多元高斯分布：条件分布

- $\boldsymbol{x}_1 \in \mathbb{R}^D$，$\boldsymbol{x}_2 \in \mathbb{R}^K$ 是两个随机向量，$\boldsymbol{x}_1$和$\boldsymbol{x}_2$的联合分布服从以下高斯分布

$$p(\boldsymbol{x}_1, \boldsymbol{x}_2) = \mathcal{N}\left(\begin{bmatrix}\boldsymbol{x}_1\\ \boldsymbol{x}_2\end{bmatrix}; \boldsymbol{\mu}, \boldsymbol{\Sigma}\right) \quad \boldsymbol{\mu} = \begin{bmatrix}\boldsymbol{\mu}_1\\ \boldsymbol{\mu}_2\end{bmatrix} \quad \boldsymbol{\Sigma} = \begin{bmatrix}\boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12}\\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22}\end{bmatrix} \quad \boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1} = \begin{bmatrix}\boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12}\\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22}\end{bmatrix}$$

- 条件分布

$$p(\boldsymbol{x}_2|\boldsymbol{x}_1) = \mathcal{N}\left(\boldsymbol{x}_2; \boldsymbol{\mu}_{2|1}, \boldsymbol{\Sigma}_{2|1}\right)$$

$$\begin{aligned}\boldsymbol{\mu}_{2|1} &= \boldsymbol{\mu}_2 + \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1 - \boldsymbol{\mu}_1)\\ &= \boldsymbol{\mu}_2 - \boldsymbol{\Lambda}_{22}^{-1}\boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1 - \boldsymbol{\mu}_1)\\ &= \boldsymbol{\Sigma}_{2|1}\left(\boldsymbol{\Lambda}_{22}\boldsymbol{\mu}_2 - \boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1 - \boldsymbol{\mu}_1)\right)\end{aligned}$$

$$\boldsymbol{\Sigma}_{2|1} = \boldsymbol{\Sigma}_{22} - \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12} = \boldsymbol{\Lambda}_{22}^{-1}$$

Why?

$$p(\boldsymbol{x}_1|\boldsymbol{x}_2) = \mathcal{N}\left(\boldsymbol{x}_1; \boldsymbol{\mu}_{1|2}, \boldsymbol{\Sigma}_{1|2}\right)$$

$$\begin{aligned}\boldsymbol{\mu}_{1|2} &= \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\boldsymbol{x}_2 - \boldsymbol{\mu}_2)\\ &= \boldsymbol{\mu}_1 - \boldsymbol{\Lambda}_{11}^{-1}\boldsymbol{\Lambda}_{12}(\boldsymbol{x}_2 - \boldsymbol{\mu}_2)\\ &= \boldsymbol{\Sigma}_{1|2}\left(\boldsymbol{\Lambda}_{11}\boldsymbol{\mu}_1 - \boldsymbol{\Lambda}_{12}(\boldsymbol{x}_2 - \boldsymbol{\mu}_2)\right)\end{aligned}$$

$$\boldsymbol{\Sigma}_{1|2} = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21} = \boldsymbol{\Lambda}_{11}^{-1}$$

矩阵求逆：舒尔补 (Schur complement)

- 方阵$\mathbf{M}=\begin{bmatrix}\mathbf{E} & \mathbf{F}\\ \mathbf{G} & \mathbf{H}\end{bmatrix}$，其中
  - $\mathbf{E}$和$\mathbf{H}$（方阵）是可逆矩阵
- $\mathbf{M}$的逆矩阵计算如下

$$\mathbf{M}^{-1}=\begin{bmatrix}(\mathbf{M}/\mathbf{H})^{-1} & -(\mathbf{M}/\mathbf{H})^{-1}\mathbf{F}\mathbf{H}^{-1}\\ -\mathbf{H}^{-1}\mathbf{G}(\mathbf{M}/\mathbf{H})^{-1} & \mathbf{H}^{-1}+\mathbf{H}^{-1}\mathbf{G}(\mathbf{M}/\mathbf{H})^{-1}\mathbf{F}\mathbf{H}^{-1}\end{bmatrix} \quad \mathbf{M}/\mathbf{H}\triangleq\mathbf{E}-\mathbf{F}\mathbf{H}^{-1}\mathbf{G}$$

$$=\begin{bmatrix}\mathbf{E}^{-1}+\mathbf{E}^{-1}\mathbf{F}(\mathbf{M}/\mathbf{E})^{-1}\mathbf{G}\mathbf{E}^{-1} & -\mathbf{E}^{-1}\mathbf{F}(\mathbf{M}/\mathbf{E})^{-1}\\ -(\mathbf{M}/\mathbf{E})^{-1}\mathbf{G}\mathbf{E}^{-1} & (\mathbf{M}/\mathbf{E})^{-1}\end{bmatrix} \quad \mathbf{M}/\mathbf{E}\triangleq\mathbf{H}-\mathbf{G}\mathbf{E}^{-1}\mathbf{F}$$

边缘分布与条件分布：推导

$$\mathbf{M} = \begin{bmatrix} \mathbf{E} & \mathbf{F} \\ \mathbf{G} & \mathbf{H} \end{bmatrix}$$

$$\mathbf{M}^{-1} = \begin{bmatrix} \mathbf{E}^{-1} + \mathbf{E}^{-1}\mathbf{F}(\mathbf{M}/\mathbf{E})^{-1}\mathbf{G}\mathbf{E}^{-1} & -\mathbf{E}^{-1}\mathbf{F}(\mathbf{M}/\mathbf{E})^{-1} \\ -(\mathbf{M}/\mathbf{E})^{-1}\mathbf{G}\mathbf{E}^{-1} & (\mathbf{M}/\mathbf{E})^{-1} \end{bmatrix} \qquad \mathbf{M}/\mathbf{E} \triangleq \mathbf{H} - \mathbf{G}\mathbf{E}^{-1}\mathbf{F}$$

$$\boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \quad \boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1} = \begin{bmatrix} \boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12} \\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22} \end{bmatrix} \qquad \boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11} \triangleq \boldsymbol{\Sigma}_{22} - \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}$$

$$\boldsymbol{\Lambda}_{11} = \boldsymbol{\Sigma}_{11}^{-1} + \boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1} \qquad \boldsymbol{\Lambda}_{12} = -\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}$$

$$\boldsymbol{\Lambda}_{21} = -(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1} \qquad \boldsymbol{\Lambda}_{22} = (\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}$$

边缘分布与条件分布：推导

$$p(\boldsymbol{x}_1, \boldsymbol{x}_2) = \mathcal{N}\left(\begin{bmatrix}\boldsymbol{x}_1\\ \boldsymbol{x}_2\end{bmatrix}; \boldsymbol{\mu}, \boldsymbol{\Sigma}\right) \qquad \boldsymbol{\mu} = \begin{bmatrix}\boldsymbol{\mu}_1\\ \boldsymbol{\mu}_2\end{bmatrix} \qquad \boldsymbol{\Sigma} = \begin{bmatrix}\boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12}\\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22}\end{bmatrix} \qquad \boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1} = \begin{bmatrix}\boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12}\\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22}\end{bmatrix}$$

$$p(\boldsymbol{x}_1, \boldsymbol{x}_2) = \mathcal{N}\left(\begin{bmatrix}\boldsymbol{x}_1\\ \boldsymbol{x}_2\end{bmatrix}; \boldsymbol{\mu}, \boldsymbol{\Sigma}\right) \triangleq \frac{1}{(2\pi)^{(D+K)/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}\begin{bmatrix}\boldsymbol{x}_1-\boldsymbol{\mu}_1\\ \boldsymbol{x}_2-\boldsymbol{\mu}_2\end{bmatrix}^{\mathrm{T}}\begin{bmatrix}\boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12}\\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22}\end{bmatrix}\begin{bmatrix}\boldsymbol{x}_1-\boldsymbol{\mu}_1\\ \boldsymbol{x}_2-\boldsymbol{\mu}_2\end{bmatrix}\right)$$

$$p(\boldsymbol{x}_1, \boldsymbol{x}_2) \propto E \triangleq \exp\left(-\frac{1}{2}\begin{bmatrix}\boldsymbol{x}_1-\boldsymbol{\mu}_1\\ \boldsymbol{x}_2-\boldsymbol{\mu}_2\end{bmatrix}^{\mathrm{T}}\begin{bmatrix}\boldsymbol{\Lambda}_{11} & \boldsymbol{\Lambda}_{12}\\ \boldsymbol{\Lambda}_{21} & \boldsymbol{\Lambda}_{22}\end{bmatrix}\begin{bmatrix}\boldsymbol{x}_1-\boldsymbol{\mu}_1\\ \boldsymbol{x}_2-\boldsymbol{\mu}_2\end{bmatrix}\right)$$

$$E = \exp\left(-\frac{1}{2}\left((\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Lambda}_{11}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) + (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Lambda}_{12}(\boldsymbol{x}_2-\boldsymbol{\mu}_2) + (\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}\boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) + (\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}\boldsymbol{\Lambda}_{22}(\boldsymbol{x}_2-\boldsymbol{\mu}_2)\right)\right)$$

$$F \triangleq (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Lambda}_{11}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) + (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Lambda}_{12}(\boldsymbol{x}_2-\boldsymbol{\mu}_2) + (\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}\boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) + (\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}\boldsymbol{\Lambda}_{22}(\boldsymbol{x}_2-\boldsymbol{\mu}_2)$$

$$E = \exp\left(-\frac{1}{2}F\right)$$

边缘分布与条件分布：推导

$$\boldsymbol{\Lambda}_{11} = \boldsymbol{\Sigma}_{11}^{-1} + \boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1} \quad \boldsymbol{\Lambda}_{12} = -\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1} \quad \boldsymbol{\Lambda}_{21} = -(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1} \quad \boldsymbol{\Lambda}_{22} = (\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}$$

$$(\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Lambda}_{11}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) = (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) + (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)$$

$$(\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Lambda}_{12}(\boldsymbol{x}_2-\boldsymbol{\mu}_2) = -(\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}(\boldsymbol{x}_2-\boldsymbol{\mu}_2)$$

$$(\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}\boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) = -(\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)$$

$$(\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}\boldsymbol{\Lambda}_{22}(\boldsymbol{x}_2-\boldsymbol{\mu}_2) = (\boldsymbol{x}_2-\boldsymbol{\mu}_2)^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}(\boldsymbol{x}_2-\boldsymbol{\mu}_2)$$

注意：$\boldsymbol{\Sigma}$和$\boldsymbol{\Sigma}_{11}$是对称矩阵，故

$$(\boldsymbol{\Sigma}_{11}^{-1})^{\mathrm{T}} = \boldsymbol{\Sigma}_{11}^{-1}$$
$$(\boldsymbol{\Sigma}_{21})^{\mathrm{T}} = \boldsymbol{\Sigma}_{12}$$

$$F = (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1) + \left(\boldsymbol{x}_2-\boldsymbol{\mu}_2-\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)\right)^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\left(\boldsymbol{x}_2-\boldsymbol{\mu}_2-\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)\right)$$

$$F_1 \triangleq (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)$$

$$F_{2|1} \triangleq \left(\boldsymbol{x}_2-\boldsymbol{\mu}_2-\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)\right)^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\left(\boldsymbol{x}_2-\boldsymbol{\mu}_2-\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)\right)$$

$$F = F_1 + F_{2|1}$$

$$\boldsymbol{\mu}_{2|1} \triangleq \boldsymbol{\mu}_2 + \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)$$

$$F_{2|1} \triangleq (\boldsymbol{x}_2-\boldsymbol{\mu}_{2|1})^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}(\boldsymbol{x}_2-\boldsymbol{\mu}_{2|1})$$

边缘分布与条件分布：推导

$F_1 \triangleq (\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)$ $\quad F_{2|1} \triangleq \left(\boldsymbol{x}_2-\boldsymbol{\mu}_{2|1}\right)^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\left(\boldsymbol{x}_2-\boldsymbol{\mu}_{2|1}\right)$ $\quad \boldsymbol{\mu}_{2|1} \triangleq \boldsymbol{\mu}_2+\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)$

$$p(\boldsymbol{x}_1,\boldsymbol{x}_2)=\frac{1}{(2\pi)^{\frac{(D+K)}{2}}|\boldsymbol{\Sigma}|^{\frac{1}{2}}}\exp\left(-\frac{1}{2}(F_1+F_{2|1})\right)=\frac{1}{(2\pi)^{\frac{(D+K)}{2}}|\boldsymbol{\Sigma}|^{\frac{1}{2}}}\exp\left(-\frac{1}{2}F_1\right)\exp\left(-\frac{1}{2}F_{2|1}\right)$$

$$p(\boldsymbol{x}_1)=\int p(\boldsymbol{x}_1,\boldsymbol{x}_2)d\boldsymbol{x}_2=\frac{1}{(2\pi)^{\frac{(D+K)}{2}}|\boldsymbol{\Sigma}|^{\frac{1}{2}}}\exp\left(-\frac{1}{2}F_1\right)\int\exp\left(-\frac{1}{2}F_{2|1}\right)d\boldsymbol{x}_2$$

$$p(\boldsymbol{x}_1,\boldsymbol{x}_2)=p(\boldsymbol{x}_1)p(\boldsymbol{x}_2|\boldsymbol{x}_1)$$

$$\propto\exp\left(-\frac{1}{2}F_1\right)\propto\frac{1}{(2\pi)^{\frac{D}{2}}|\boldsymbol{\Sigma}_{11}|^{\frac{1}{2}}}\exp\left(-\frac{1}{2}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)^{\mathrm{T}}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1)\right)$$

$$p(\boldsymbol{x}_2|\boldsymbol{x}_1)\propto\exp\left(-\frac{1}{2}F_{2|1}\right)$$

$$p(\boldsymbol{x}_1)=\mathcal{N}(\boldsymbol{x}_1;\boldsymbol{\mu}_1,\boldsymbol{\Sigma}_{11})$$

$$\boldsymbol{\Sigma}_{2|1}\triangleq\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11}=\boldsymbol{\Sigma}_{22}-\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}$$

$$p(\boldsymbol{x}_2|\boldsymbol{x}_1)=\frac{1}{(2\pi)^{\frac{K}{2}}|(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})|^{\frac{1}{2}}}\exp\left(-\frac{1}{2}\left(\boldsymbol{x}_2-\boldsymbol{\mu}_{2|1}\right)^{\mathrm{T}}(\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{11})^{-1}\left(\boldsymbol{x}_2-\boldsymbol{\mu}_{2|1}\right)\right)$$

多元高斯分布：示例

$$\boldsymbol{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \boldsymbol{x} \in \mathbb{R}^2$$

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \qquad \boldsymbol{\Sigma} = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

$$\Sigma_{ii} \triangleq \sigma_i^2$$

$$\Sigma_{ij} \triangleq \mathrm{Cov}[X_i, X_j] = \rho\sqrt{\mathbb{V}[X_i]\mathbb{V}[X_j]} = \rho\sigma_i\sigma_j$$

$$\Big\Downarrow \text{舒尔补}$$

$$\boldsymbol{\Sigma}^{-1} = \begin{bmatrix} \dfrac{1}{\sigma_1^2(1-\rho^2)} & -\dfrac{\rho}{\sigma_1\sigma_2(1-\rho^2)} \\ -\dfrac{\rho}{\sigma_1\sigma_2(1-\rho^2)} & \dfrac{1}{\sigma_2^2(1-\rho^2)} \end{bmatrix} = \frac{1}{(1-\rho^2)} \begin{bmatrix} \dfrac{1}{\sigma_1^2} & -\dfrac{\rho}{\sigma_1\sigma_2} \\ -\dfrac{\rho}{\sigma_1\sigma_2} & \dfrac{1}{\sigma_2^2} \end{bmatrix}$$

$$p\left(\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) \triangleq p(x_1, x_2)$$

$$p(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} \times \left(\frac{(x_1-\mu_1)^2}{\sigma_1^2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho \times \frac{x_1-\mu_1}{\sigma_1}\frac{x_2-\mu_2}{\sigma_2}\right)\right)$$

多元高斯分布：示例

边缘分布

$$p(x_1) = \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{1}{2\sigma_1^2} \times (x_1 - \mu_1)^2\right) \qquad p(x_2) = \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(-\frac{1}{2\sigma_2^2} \times (x_2 - \mu_2)^2\right)$$

$$p(\boldsymbol{x}_2|\boldsymbol{x}_1) = \mathcal{N}\left(\boldsymbol{x}_2; \boldsymbol{\mu}_{2|1}, \boldsymbol{\Sigma}_{2|1}\right)$$

$$\begin{aligned}\boldsymbol{\mu}_{2|1} &= \boldsymbol{\mu}_2 + \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}(\boldsymbol{x}_1 - \boldsymbol{\mu}_1) \\ &= \boldsymbol{\mu}_2 - \boldsymbol{\Lambda}_{22}^{-1}\boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1 - \boldsymbol{\mu}_1) \\ &= \boldsymbol{\Sigma}_{2|1}\left(\boldsymbol{\Lambda}_{22}\boldsymbol{\mu}_2 - \boldsymbol{\Lambda}_{21}(\boldsymbol{x}_1 - \boldsymbol{\mu}_1)\right)\end{aligned}$$

$$\boldsymbol{\Sigma}_{2|1} = \boldsymbol{\Sigma}_{22} - \boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12} = \boldsymbol{\Lambda}_{22}^{-1}$$

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \qquad \boldsymbol{\Sigma}^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2(1-\rho^2)} & -\frac{\rho}{\sigma_1\sigma_2(1-\rho^2)} \\ -\frac{\rho}{\sigma_1\sigma_2(1-\rho^2)} & \frac{1}{\sigma_2^2(1-\rho^2)} \end{bmatrix}$$

$$\mu_{2|1} = \mu_2 + \frac{\rho\sigma_1\sigma_2}{\sigma_1^2(1-\rho^2)}(x_1 - \mu_1)$$

$$\Sigma_{2|1} = \sigma_2^2 - \rho\sigma_1\sigma_2\frac{1}{\sigma_1^2}\rho\sigma_1\sigma_2 = \sigma_2^2(1-\rho^2)$$

条件分布 $p(x_2|x_1) = \mathcal{N}\left(x_2; \mu_{2|1}, \Sigma_{2|1}\right)$

指数分布族

- 指数分布族 (the exponential family)
- 由参数$\boldsymbol{\theta} \in \mathbb{R}^K$刻画的一类概率分布形式$p(\boldsymbol{x};\boldsymbol{\theta})$，其中随机变量$\boldsymbol{x} \in \mathbb{R}^D$

$$p(\boldsymbol{x};\boldsymbol{\theta}) \triangleq \frac{1}{Z(\boldsymbol{\theta})} h(\boldsymbol{x}) \exp[\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})] = h(\boldsymbol{x}) \exp[\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x}) - A(\boldsymbol{\theta})]$$

  - $\boldsymbol{x} \in \mathbb{R}^D$：随机变量
  - $h(\boldsymbol{x})$：基础度量 (base measure)
  - $\phi(\boldsymbol{x}) \in \mathbb{R}^K$：充分统计量 (sufficient statistics)
    - ✓ $\phi(\boldsymbol{x}) = \boldsymbol{x}$，称为自然指数分布族 (natural exponential family)
  - $\boldsymbol{\theta} \in \mathbb{R}^K$：自然参数 (natural parameter)，或规范参数 (canonical parameter)
  - $Z(\boldsymbol{\theta})$：配分函数(partition function)，保证对概率密度函数求积分等于1
  - $A(\boldsymbol{\theta})$：对数配分函数(log partition function)

指数分布族示例：伯努利分布

伯努利分布：$x \in \{0,1\}, \mu = P(1)$

$$
\begin{aligned}
p(x) &= \mu^x (1-\mu)^{1-x} \\
&= \exp(x \log \mu + (1-x)\log(1-\mu)) \\
&= \exp\left(\boldsymbol{\theta}^{\mathrm{T}} \phi(x)\right)
\end{aligned}
$$

$$
\phi(x) \triangleq \begin{bmatrix} \mathbb{I}(x=1) \\ \mathbb{I}(x=0) \end{bmatrix} \quad \boldsymbol{\theta} \triangleq \begin{bmatrix} \log \mu \\ \log(1-\mu) \end{bmatrix}
$$

$$
\begin{bmatrix} 1 \\ 1 \end{bmatrix}^{\mathrm{T}} \phi(x) = \mathbb{I}(x \underbrace{= 1) + \mathbb{I}(x}_{\text{线性依赖}} = 0) = 1
$$

$$
\begin{aligned}
p(x) &= \mu^x (1-\mu)^{1-x} \\
&= \exp(x \log \mu + (1-x)\log(1-\mu)) \\
&= \exp\left(x \log \frac{\mu}{1-\mu} + \log(1-\mu)\right) \\
&= \exp(\theta x - A(\theta))
\end{aligned}
$$

$$\theta \triangleq \log \frac{\mu}{1-\mu} \Rightarrow \mu = \frac{1}{1+e^{-\theta}}$$

$$\phi(x) \triangleq x$$

$$h(x) \triangleq 1$$

$$A(\theta) \triangleq -\log(1-\mu) = \log\left(1+e^{\theta}\right)$$

ITML 指数分布族示例：高斯分布

$$p(x) = \mathcal{N}(x;\mu,\sigma^2) \triangleq \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x - \frac{1}{2\sigma^2}\mu^2\right)$$

$$= \exp\left(-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x - \left(\frac{\mu^2}{2\sigma^2} + \frac{\log(2\pi\sigma^2)}{2}\right)\right)$$

$$\phi(\boldsymbol{x}) = \begin{bmatrix}\phi_1(x)\\ \phi_2(x)\end{bmatrix} \triangleq \begin{bmatrix}x\\ x^2\end{bmatrix} \quad \boldsymbol{\theta} = \begin{bmatrix}\theta_1\\ \theta_2\end{bmatrix} \triangleq \begin{bmatrix}\frac{\mu}{\sigma^2}\\ -\frac{1}{2\sigma^2}\end{bmatrix} \quad A(\boldsymbol{\theta}) = \frac{\mu^2}{2\sigma^2} + \frac{\log(2\pi\sigma^2)}{2} = -\frac{\theta_1^2}{4\theta_2} - \frac{1}{2}\log(-2\theta_2) + \frac{1}{2}\log 2\pi$$

$$= \exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x}) - A(\boldsymbol{\theta})\right)$$

指数分布族：期望与方差

自然参数为一维的情况，即$\boldsymbol{\theta} \in \mathbb{R}$

$$A'(\theta) = \frac{dA(\theta)}{d\theta} = \mathbb{E}[\phi(\boldsymbol{X})]$$

$$A''(\theta) = \frac{d^2A(\theta)}{d\theta^2} = \mathbb{V}[\phi(\boldsymbol{X})]$$

自然参数为多维的情况，即$\boldsymbol{\theta} \in \mathbb{R}^K (K > 1)$

$$\nabla A(\boldsymbol{\theta}) = \frac{\partial A(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbb{E}[\phi(\boldsymbol{X})]$$

$$\nabla^2 A(\boldsymbol{\theta}) = \frac{\partial}{\partial \boldsymbol{\theta}^{\mathrm{T}}} \frac{\partial A(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathrm{Cov}[\phi(\boldsymbol{X})]$$

指数分布族：期望

自然参数为一维的情况，即$\boldsymbol{\theta} \in \mathbb{R}$

$$A(\theta) = \log Z(\theta) = \log \int h(\boldsymbol{x}) \exp\big(\theta \phi(\boldsymbol{x})\big) d\boldsymbol{x}$$

$$\frac{dA(\theta)}{d\theta} = \frac{d\log Z(\theta)}{d\theta} = \frac{d\log Z(\theta)}{dZ(\theta)} \frac{dZ(\theta)}{d\theta} = \frac{1}{Z(\theta)} \int h(\boldsymbol{x}) \frac{d}{d\theta} \exp\big(\theta \phi(\boldsymbol{x})\big) d\boldsymbol{x}$$

$$= \frac{1}{Z(\theta)} \int h(\boldsymbol{x}) \frac{d\exp\big(\theta \phi(\boldsymbol{x})\big)}{d\theta \phi(\boldsymbol{x})} \frac{d\theta \phi(\boldsymbol{x})}{d\theta} d\boldsymbol{x}$$

$$= \frac{1}{Z(\theta)} \int h(\boldsymbol{x}) \exp\big(\theta \phi(\boldsymbol{x})\big) \phi(\boldsymbol{x}) d\boldsymbol{x}$$

$$= \mathbb{E}[\phi(\boldsymbol{X})]$$

ITML

指数分布族：期望

自然参数为多维的情况，即$\boldsymbol{\theta} \in \mathbb{R}^K (K > 1)$

$$\frac{\partial A(\boldsymbol{\theta})}{\partial \theta_i} = \frac{\partial \log Z(\boldsymbol{\theta})}{\partial \theta_i} = \frac{\partial \log Z(\boldsymbol{\theta})}{\partial Z(\boldsymbol{\theta})} \frac{\partial Z(\boldsymbol{\theta})}{\partial \theta_i} = \frac{1}{Z(\boldsymbol{\theta})} \int h(\boldsymbol{x}) \frac{\partial}{\partial \theta_i} \exp\left(\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})\right) d\boldsymbol{x}$$

$$= \frac{1}{Z(\boldsymbol{\theta})} \int h(\boldsymbol{x}) \frac{\partial \exp\left(\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})\right)}{\partial \boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})} \frac{\partial \boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})}{\partial \theta_i} d\boldsymbol{x}$$

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_K \end{bmatrix}$$

$$= \frac{1}{Z(\boldsymbol{\theta})} \int h(\boldsymbol{x}) \exp\left(\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})\right) \frac{\partial \sum_{k=1}^K \theta_k \phi_k(\boldsymbol{x})}{\partial \theta_i} d\boldsymbol{x}$$

$$\phi(\boldsymbol{x}) = \begin{bmatrix} \phi_1(\boldsymbol{x}) \\ \vdots \\ \phi_K(\boldsymbol{x}) \end{bmatrix}$$

$$= \frac{1}{Z(\boldsymbol{\theta})} \int h(\boldsymbol{x}) \exp\left(\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x})\right) \phi_i(\boldsymbol{x}) d\boldsymbol{x} = \mathbb{E}[\phi_i(\boldsymbol{X})]$$

$$\nabla A(\boldsymbol{\theta}) = \frac{\partial A(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \begin{bmatrix} \frac{\partial A(\boldsymbol{\theta})}{\partial \theta_1} \\ \vdots \\ \frac{\partial A(\boldsymbol{\theta})}{\partial \theta_K} \end{bmatrix} = \begin{bmatrix} \mathbb{E}[\phi_1(\boldsymbol{X})] \\ \vdots \\ \mathbb{E}[\phi_K(\boldsymbol{X})] \end{bmatrix} = \mathbb{E}[\phi(\boldsymbol{X})]$$

$$\boldsymbol{\theta}^{\mathrm{T}} \phi(\boldsymbol{x}) = \sum_{k=1}^{K} \theta_k \phi_k(\boldsymbol{x})$$

指数分布族：方差

自然参数为一维的情况，即$\boldsymbol{\theta} \in \mathbb{R}$

$$\frac{dZ(\theta)}{d\theta} = \int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x}$$

$$
\begin{aligned}
\frac{d^2A(\theta)}{d\theta^2} &= \frac{d}{d\theta}\left(\frac{dA(\theta)}{d\theta}\right) \\
&= \frac{d}{d\theta}\left(\frac{1}{Z(\theta)}\int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x}\right) \\
&= \frac{d}{d\theta}\left(\frac{1}{Z(\theta)}\right)\int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x} + \frac{1}{Z(\theta)}\frac{d}{d\theta}\int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x} \\
&= -\frac{1}{\big(Z(\theta)\big)^2}\frac{dZ(\theta)}{d\theta}\int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x} + \frac{1}{Z(\theta)}\int h(\boldsymbol{x})\frac{d}{d\theta}\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x} \\
&= -\frac{1}{\big(Z(\theta)\big)^2}\left(\int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\phi(\boldsymbol{x})d\boldsymbol{x}\right)^2 + \frac{1}{Z(\theta)}\int h(\boldsymbol{x})\exp\big(\theta\phi(\boldsymbol{x})\big)\big(\phi(\boldsymbol{x})\big)^2d\boldsymbol{x} \\
&= -(\mathbb{E}[\phi(\boldsymbol{X})])^2 + \mathbb{E}\left[\big(\phi(\boldsymbol{X})\big)^2\right] = \mathbb{V}[\phi(\boldsymbol{X})]
\end{aligned}
$$

指数分布族：协方差

自然参数为多维的情况，即$\boldsymbol{\theta} \in \mathbb{R}^K (K > 1)$

$$\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x}) = \sum_{k=1}^{K} \theta_k \phi_k(\boldsymbol{x})$$

$$\frac{dZ(\boldsymbol{\theta})}{d\theta_i} = \int h(\boldsymbol{x})\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x})\right)\phi_i(\boldsymbol{x})d\boldsymbol{x}$$

$$\frac{\partial^2 A(\boldsymbol{\theta})}{\partial\theta_j \partial\theta_i} = \frac{\partial}{\partial\theta_j}\frac{\partial A(\boldsymbol{\theta})}{\partial\theta_i} = \frac{\partial}{\partial\theta_j}\left(\frac{1}{Z(\boldsymbol{\theta})}\int h(\boldsymbol{x})\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x})\right)\phi_i(\boldsymbol{x})d\boldsymbol{x}\right)$$

$$= \frac{\partial \frac{1}{Z(\boldsymbol{\theta})}}{\partial\theta_j}\int h(\boldsymbol{x})\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x})\right)\phi_i(\boldsymbol{x})d\boldsymbol{x} + \frac{1}{Z(\boldsymbol{\theta})}\frac{\partial \int h(\boldsymbol{x})\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x})\right)\phi_i(\boldsymbol{x})d\boldsymbol{x}}{\partial\theta_j}$$

$$= -\frac{1}{\left(Z(\boldsymbol{\theta})\right)^2}\frac{dZ(\boldsymbol{\theta})}{d\boldsymbol{\theta_j}}\int h(\boldsymbol{x})\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x})\right)\phi_i(\boldsymbol{x})d\boldsymbol{x} + \frac{1}{Z(\boldsymbol{\theta})}\frac{\partial \int h(\boldsymbol{x})\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(\boldsymbol{x})\right)\phi_i(\boldsymbol{x})d\boldsymbol{x}}{\partial\theta_j}$$

$$= -\mathbb{E}\left[\phi_j(\boldsymbol{X})\right]\mathbb{E}[\phi_i(\boldsymbol{X})] + \mathbb{E}\left[\phi_j(\boldsymbol{X})\phi_i(\boldsymbol{X})\right] = \mathrm{Cov}\left[\phi_j(\boldsymbol{X}), \phi_i(\boldsymbol{X})\right]$$

海森矩阵

$$\nabla^2 A(\boldsymbol{\theta}) = \frac{\partial}{\partial\boldsymbol{\theta}^{\mathrm{T}}}\frac{\partial A(\boldsymbol{\theta})}{\partial\boldsymbol{\theta}} = \begin{bmatrix} \frac{\partial^2 A(\boldsymbol{\theta})}{\partial\theta_1\partial\theta_1} & \cdots & \frac{\partial^2 A(\boldsymbol{\theta})}{\partial\theta_1\partial\theta_K} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 A(\boldsymbol{\theta})}{\partial\theta_K\partial\theta_1} & \cdots & \frac{\partial^2 A(\boldsymbol{\theta})}{\partial\theta_K\partial\theta_K} \end{bmatrix} = \begin{bmatrix} \mathrm{Cov}[\phi_1(\boldsymbol{X}), \phi_1(\boldsymbol{X})] & \cdots & \mathrm{Cov}[\phi_1(\boldsymbol{X}), \phi_K(\boldsymbol{X})] \\ \vdots & \ddots & \vdots \\ \mathrm{Cov}[\phi_K(\boldsymbol{X}), \phi_1(\boldsymbol{X})] & \cdots & \mathrm{Cov}[\phi_K(\boldsymbol{X}), \phi_K(\boldsymbol{X})] \end{bmatrix} = \mathrm{Cov}[\phi(\boldsymbol{X})]$$

指数分布族期望与方差：示例

$$p(x)=\mathcal{N}(x;\mu,\sigma^2)=\exp\left(\boldsymbol{\theta}^{\mathrm{T}}\phi(x)-A(\boldsymbol{\theta})\right)$$

$$\phi(x)=\begin{bmatrix}\phi_1(x)\\ \phi_2(x)\end{bmatrix}\triangleq\begin{bmatrix}x\\ x^2\end{bmatrix}$$

$$\boldsymbol{\theta}=\begin{bmatrix}\theta_1\\ \theta_2\end{bmatrix}\triangleq\begin{bmatrix}\dfrac{\mu}{\sigma^2}\\ -\dfrac{1}{2\sigma^2}\end{bmatrix}$$

$$A(\boldsymbol{\theta})=\frac{\mu^2}{2\sigma^2}+\frac{\log(2\pi\sigma^2)}{2}$$
$$=-\frac{\theta_1^2}{4\theta_2}-\frac{1}{2}\log(-2\theta_2)+\frac{1}{2}\log 2\pi$$

$$\frac{\partial A(\boldsymbol{\theta})}{\partial\theta_1}=\frac{\partial}{\partial\theta_1}\left(-\frac{\theta_1^2}{4\theta_2}-\frac{1}{2}\log(-2\theta_2)+\frac{1}{2}\log 2\pi\right)$$
$$=-\frac{1}{2}\theta_1\frac{1}{\theta_2}=-\frac{1}{2}\frac{\mu}{\sigma^2}(-2\sigma^2)=\mu=\mathbb{E}[X]$$

$$\frac{\partial A(\boldsymbol{\theta})}{\partial\theta_2}=\frac{\partial}{\partial\theta_2}\left(-\frac{\theta_1^2}{4\theta_2}-\frac{1}{2}\log(-2\theta_2)+\frac{1}{2}\log 2\pi\right)$$
$$=\frac{\theta_1^2}{4\theta_2^2}-\frac{1}{2\theta_2}=\frac{1}{4}\left(\frac{\mu}{\sigma^2}\right)^2(-2\sigma^2)^2-\frac{1}{2}(-2\sigma^2)$$
$$=\mu^2+\sigma^2=\mathbb{E}[X^2]$$

$$\mathbb{E}[\phi(X)]=\mathbb{E}\left[\begin{bmatrix}X\\ X^2\end{bmatrix}\right]=\begin{bmatrix}\mathbb{E}[X]\\ \mathbb{E}[X^2]\end{bmatrix}=\begin{bmatrix}\dfrac{\partial A(\boldsymbol{\theta})}{\partial\theta_1}\\ \dfrac{\partial A(\boldsymbol{\theta})}{\partial\theta_2}\end{bmatrix}=\frac{\partial A(\boldsymbol{\theta})}{\partial\boldsymbol{\theta}}$$

指数分布族期望与方差：示例

$$\frac{\partial A(\boldsymbol{\theta})}{\partial \theta_1} = -\frac{1}{2}\frac{\theta_1}{\theta_2} \qquad \frac{\partial A(\boldsymbol{\theta})}{\partial \theta_2} = \frac{\theta_1^2}{4\theta_2^2} - \frac{1}{2\theta_2}$$

$$\boldsymbol{\theta} = \begin{bmatrix}\theta_1\\ \theta_2\end{bmatrix} \triangleq \begin{bmatrix}\frac{\mu}{\sigma^2}\\ -\frac{1}{2\sigma^2}\end{bmatrix}$$

$$\phi(x) = \begin{bmatrix}\phi_1(x)\\ \phi_2(x)\end{bmatrix} \triangleq \begin{bmatrix}x\\ x^2\end{bmatrix}$$

$$\frac{\partial}{\partial \theta_1}\frac{\partial A(\boldsymbol{\theta})}{\partial \theta_1} = -\frac{1}{2}\frac{1}{\theta_2} = \sigma^2 \qquad \frac{\partial}{\partial \theta_1}\frac{\partial A(\boldsymbol{\theta})}{\partial \theta_2} = \frac{1}{2}\frac{\theta_1}{\theta_2^2} = 2\mu\sigma^2$$

$$\frac{\partial}{\partial \theta_2}\frac{\partial A(\boldsymbol{\theta})}{\partial \theta_1} = \frac{1}{2}\frac{\theta_1}{\theta_2^2} = 2\mu\sigma^2$$

原点矩
(raw moment)

$$\frac{\partial}{\partial \theta_2}\frac{\partial A(\boldsymbol{\theta})}{\partial \theta_2} = -\frac{1}{2}\frac{\theta_1^2}{\theta_2^3} + \frac{1}{2}\frac{1}{\theta_2^2} = 2\sigma^2(\sigma^2 + 2\mu^2)$$

$$\mathrm{Cov}[\phi_1(X), \phi_1(X)] = \mathrm{Cov}[X, X] = \boxed{\mathbb{E}[X^2]} - (\mathbb{E}[X])^2 = \mathbb{V}[X] = \sigma^2 \Longrightarrow \mathbb{E}[X^2] = \mu^2 + \sigma^2$$

$$\mathrm{Cov}[\phi_1(X), \phi_2(X)] = \mathrm{Cov}[X, X^2] = \boxed{\mathbb{E}[X^3]} - \mathbb{E}[X]\mathbb{E}[X^2] = 2\mu\sigma^2 \Longrightarrow \mathbb{E}[X^3] = \mu^3 + 3\mu\sigma^2$$

$$\mathrm{Cov}[\phi_2(X), \phi_2(X)] = \mathrm{Cov}[X^2, X^2] = \boxed{\mathbb{E}[X^4]} - (\mathbb{E}[X^2])^2 = 2\sigma^2(\sigma^2 + 2\mu^2) \Longrightarrow \mathbb{E}[X^4] = \mu^4 + 6\mu^2\sigma^2 + 3\sigma^4$$

概率分布的度量

- 给定随机变量及其上概率分布，需要度量
  - 随机变量（概率分布）的不确定性
  - 概率分布之间的差异性
- 信息理论提供相关工具
  - 不确定性
    - ✓熵 (entropy)
    - ✓联合熵 (joint entropy)
    - ✓条件熵 (conditional entropy)
  - 差异性
    - ✓交叉熵 (cross entropy)
    - ✓KL散度 (Kullback-Leibler divergence, KL divergence)

熵

- 离散型随机变量X

$$\mathbb{H}(X) \triangleq -\sum_{s=1}^{S} P(X = x_s) \log P(X = x_s) = -\sum_{s=1}^{S} p(x_s) \log p(x_s)$$

  - $p(\quad)$是概率质量函数
  - 也称离散熵，简称熵，熵是非负数

- 连续型随机变量

$$\mathbb{H}(X) \triangleq -\int p(x) \log p(x) dx$$

  - $p(\quad)$是概率密度函数
  - 也称微分熵（注意：不同于离散熵，微分熵是可以小于0）

注意：
为在机器学习领域讨论方便，缺省情况下，对数以自然数e为底。如特殊情况下需要以2为底，则标出底数2，即$\log_2$

熵：例子

- 离散型随机变量X
  - 随机抛一次硬币A，是猜正面朝上呢？还是反面朝上？
  - 随机抛一次硬币B，如何猜？

硬币A

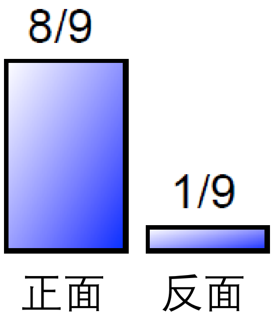

$$-\frac{8}{9}\log\frac{8}{9}-\frac{1}{9}\log\frac{1}{9}\approx 0.211$$

硬币B

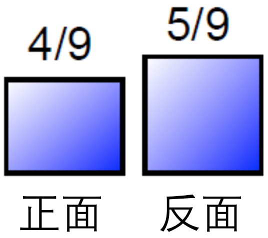

$$-\frac{4}{9}\log\frac{4}{9}-\frac{5}{9}\log\frac{5}{9}\approx 0.686$$

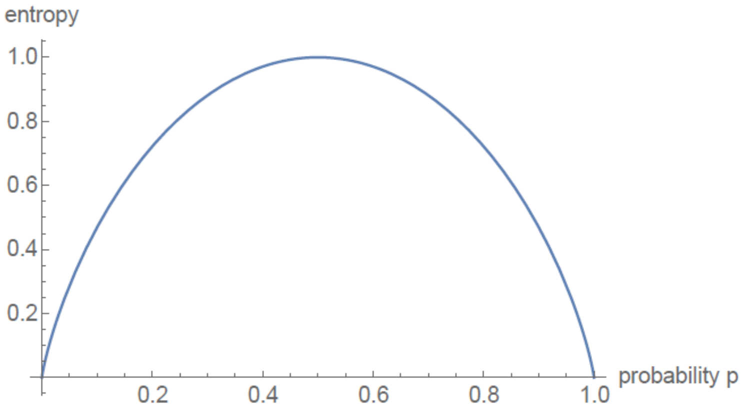

联合熵

- 随机变量X和Y，其联合熵定义如下

$$\mathbb{H}(X,Y) \triangleq -\sum_{x,y} p(x,y)\log p(x,y)$$

- 例子： $x \in$ {雨天，非雨天}，$y \in$ {晴天，非晴天}

X \ Y	晴天	非晴天
雨天	0.01	0.24
非雨天	0.25	0.50

$$H(X,Y) = -0.01\log 0.01 - 0.24\log 0.24 - 0.25\log 0.25 - 0.5\log 0.5$$

$$\approx 1.08$$

条件熵

- 给定随机变量X，随机变量Y的条件熵定义如下

$$
\begin{aligned}
\mathbb{H}(Y|X) \triangleq \mathbb{E}_{X\sim p(x)}[\mathbb{H}(Y|X=x)] &= -\sum_x p(x)\sum_y p(y|x)\log p(y|x) \\
&= -\sum_x\sum_y p(x,y)\log p(y|x) \\
&= -\sum_x\sum_y p(x,y)\log\frac{p(x,y)}{p(x)} \\
&= -\sum_x\sum_y p(x,y)\log p(x,y) + \sum_x p(x)\log p(x) \\
&= \mathbb{H}(X,Y) - \mathbb{H}(X)
\end{aligned}
$$

条件熵：示例

$x \in$ {雨天，非雨天}，$y \in$ {晴天，非晴天}

X \ Y	晴天	非晴天
雨天	0.01	0.24
非雨天	0.25	0.50

$$\mathbb{H}(Y|X) = \mathbb{E}_{X\sim p(x)}[\mathbb{H}(Y|X=x)]$$

$$= p(X=\text{雨天})\mathbb{H}(Y|X=\text{雨天}) + p(X=\text{非雨天})\mathbb{H}(Y|X=\text{非雨天})$$

$$= p(\text{雨天})\mathbb{H}(Y|\text{雨天}) + p(\text{非雨天})\mathbb{H}(Y|\text{非雨天})$$

$$= 0.25\mathbb{H}(Y|\text{雨天}) + 0.75\mathbb{H}(Y|\text{非雨天})$$

$$\mathbb{H}(Y|\text{雨天}) = -\frac{1}{25}\log\frac{1}{25} - \frac{24}{25}\log\frac{24}{25} \qquad \mathbb{H}(Y|\text{非雨天}) = -\frac{1}{3}\log\frac{1}{3} - \frac{2}{3}\log\frac{2}{3}$$

熵的主要性质

- $0 \le \mathbb{H}(X) \le \log|\mathcal{X}| = \log S$，当$X$服从均匀分布时，其熵取得最大值
- $0 \le \mathbb{H}(Y|X) \le \mathbb{H}(Y)$
  - 如果知道X，我们对Y不确定性的认知不会增大
- $\max\{\mathbb{H}(X), \mathbb{H}(Y)\} \le \mathbb{H}(X, Y) \le \mathbb{H}(X) + \mathbb{H}(Y)$
  - 不能仅通过增加变量来减少熵而使得问题更好处理
- 链式法则（Chain Rule）：$\mathbb{H}(X, Y) = \mathbb{H}(X) + \mathbb{H}(Y|X) = \mathbb{H}(Y) + \mathbb{H}(X|Y)$
- 如果X和Y相互独立，则：$\mathbb{H}(Y|X) = \mathbb{H}(Y)$
  - 这意味着X不影响我们对Y不确定性的认知
- $\mathbb{H}(Y|Y)$=0
  - 如果事先知道Y，那么我们对Y的认知是确定的

熵的主要性质：证明

均匀分布时，其熵取得最大值

$$\mathbb{H}(X) = -\sum_{s=1}^{S} p(x_s) \log p(x_s)$$

$$\max_{\{p(x_s)\}} \mathbb{H}(X) = \max_{\{p(x_s)\}} \left(-\sum_{s=1}^{S} p(x_s) \log p(x_s) \right) = \min_{\{p(x_s)\}} \sum_{s=1}^{S} p(x_s) \log p(x_s)$$

约束条件： $\sum_{s=1}^{S} p(x_s) = 1$

带等式约束的极值问题，

可用拉格朗日乘子法求解

熵的主要性质：证明

均匀分布时，其熵取得最大值

拉格朗日函数

$$\mathcal{L}(p(x_1),\dots,p(x_S)) = \sum_{s=1}^{S} p(x_s)\log p(x_s) + \lambda\left(1-\sum_{s=1}^{S} p(x_s)\right)$$

拉格朗日乘子

(对每个等式约束引入一个拉格朗日乘子)

$$\frac{\partial \mathcal{L}}{\partial p(x_s)} = 0 \Rightarrow p(x_s) = \exp(\lambda - 1)$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = 0 \Rightarrow \sum_{s=1}^{S} p(x_s) = 1$$

$$\exp(\lambda - 1) = \frac{1}{S} \quad \Rightarrow \quad p(x_s) = \frac{1}{S}$$

注意：熵是严格上凸函数，其极大值记为最大值，其唯一

熵的主要性质：证明

$$\mathbb{H}(Y|X) \le \mathbb{H}(Y)$$

$$\mathbb{H}(Y|X) = -\sum_x p(x)\sum_y p(y|x)\log p(y|x)$$

$$= -\sum_y\sum_x p(x)p(y|x)\log p(y|x)$$

$$= \sum_y -\sum_x p(x)p(y|x)\log p(y|x)$$

$$\le \sum_y -p(y)\text{log}p(y) = \mathbb{H}(Y)$$

$f(u) = -u\log u$是上凸函数

$$\Downarrow$$

$$f\left(\sum_i \lambda_i u_i\right) \ge \sum_i \lambda_i f(u_i) \quad \lambda_i \ge 0, \sum_i \lambda_i = 1$$

$$\lambda_x = p(x) \quad \Downarrow \quad u_x = p(y|x)$$

$$f\left(\sum_x p(x)p(y|x)\right) \ge \sum_x p(x)\left(-p(y|x)\text{log}p(y|x)\right)$$

$$\Downarrow$$

$$-p(y)\text{log}p(y) \ge -\sum_x p(x)p(y|x)\text{log}p(y|x)$$

熵的主要性质：证明

$$\max\{\mathbb{H}(X), \mathbb{H}(Y)\} \le \mathbb{H}(X,Y) \le \mathbb{H}(X) + \mathbb{H}(Y)$$

$$\mathbb{H}(X,Y) = \mathbb{H}(X) + \mathbb{H}(Y|X) = \mathbb{H}(Y) + \mathbb{H}(X|Y)$$

$$0 \le \mathbb{H}(Y|X), 0 \le \mathbb{H}(X|Y)$$

$$\Downarrow$$

$$\mathbb{H}(X) \le \mathbb{H}(X,Y)$$

$$\mathbb{H}(Y) \le \mathbb{H}(X,Y)$$

$$\Downarrow$$

$$\max\{\mathbb{H}(X), \mathbb{H}(Y)\} \le \mathbb{H}(X,Y)$$

$$\mathbb{H}(X,Y) = \mathbb{H}(X) + \mathbb{H}(Y|X)$$

$$\mathbb{H}(Y|X) \le \mathbb{H}(Y)$$

$$\Downarrow$$

$$\mathbb{H}(X,Y) \le \mathbb{H}(X) + \mathbb{H}(Y)$$

交叉熵

- 给定随机变量X上的两个分布p和q，其交叉熵定义如下
  - 离散型随机变量

$$\mathbb{H}(p,q) \triangleq -\sum_{x} p(x)\log q(x)$$

  - 连续型随机变量

$$\mathbb{H}(p,q) \triangleq -\int p(x)\log q(x)dx$$

- 主要用于度量两个概率分布间的差异性信息，当$q = p$时，交叉熵最小

$$p = \underset{q}{\operatorname{argmin}}\, \mathbb{H}(p,q)$$

KL散度

- 也称相对熵 (relative entropy)，是两个概率分布间差异度量方法
- 给定随机变量X上的两个分布p和q，其KL散度定义如下
  - 离散型随机变量

$$\mathrm{KL}(p \parallel q) \triangleq \sum_x p(x) \log \frac{p(x)}{q(x)} = -\sum_x p(x) \log \frac{q(x)}{p(x)} = \mathbb{E}_{x \sim p(x)} \left[\log \frac{p(x)}{q(x)} \right]$$

  - 连续型随机变量

$$\mathrm{KL}(p \parallel q) \triangleq \int p(x) \log \frac{p(x)}{q(x)} dx = -\int p(x) \log \frac{q(x)}{p(x)} dx = \mathbb{E}_{x \sim p(x)} \left[\log \frac{p(x)}{q(x)} \right]$$

- KL散度不具有对称性，不是距离度量

$$\mathrm{KL}(p \parallel q) \neq \mathrm{KL}(q \parallel p)$$

KL散度：性质

- 主要性质
  - $\mathrm{KL}(p \parallel q) \geq 0$
  - 当且仅当$p = q$时， $\mathrm{KL}(p \parallel q) = 0$
- 与交叉熵的关系

$$\mathrm{KL}(p \parallel q) = -\sum_x p(x) \log \frac{q(x)}{p(x)}$$

$$= -\sum_x p(x) \log q(x) + \sum_x p(x) \log p(x)$$

$$= \mathbb{H}(p, q) - \mathbb{H}(p)$$

同理，连续情况下可得出相同的结论。

KL散度主要性质：证明

$$\mathrm{KL}(p \parallel q) \geq 0$$

$f(u) = -\log u$是下凸函数

Jensen不等式

$$f\left(\sum_i \lambda_i u_i\right) \leq \sum_i \lambda_i f(u_i) \quad \lambda_i \geq 0, \sum_i \lambda_i = 1$$

$\lambda_x = p(x)$　　$u_x = \dfrac{q(x)}{p(x)}$

$$f\left(\sum_x p(x)\frac{q(x)}{p(x)}\right) \leq \sum_x p(x) f\left(\frac{q(x)}{p(x)}\right)$$

$$f\left(\sum_x q(x)\right) \leq \sum_x p(x)\left(-\log\frac{q(x)}{p(x)}\right) \Longrightarrow 0 \leq \mathrm{KL}(p \parallel q)$$

对连续情况，下凸函数有类似性质，同理可推出$\mathrm{KL}(p,q) \geq 0$

$f(u) = -\log u$是下凸函数

$$f\left(\int g(x)p(x)dx\right) \leq \int f\big(g(x)\big)p(x)dx$$

由于$-\log u$是严格下凸函数，不等式两边相等的充分必要条件$p = q$

KL散度：讨论

- 假定任务需要用相对简单分布$q(x)$去近似分布$p(x)$，有以下两种方法

  - $\min_q \mathrm{KL}(p \parallel q)$

    ✓$\mathrm{KL}(p \parallel q)$也称前向KL散度 (forwards KL，常用)

$$\mathrm{KL}(p \parallel q) \triangleq \mathbb{E}_{x\sim p(x)}\left[\log\frac{p(x)}{q(x)}\right]$$

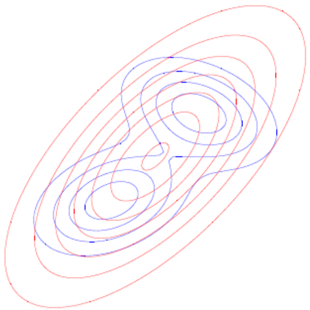

  - $\min_q \mathrm{KL}(q, p)$

    ✓$\mathrm{KL}(q \parallel p)$也称逆向KL散度 (reverse KL)

$$\mathrm{KL}(q \parallel p) \triangleq \mathbb{E}_{x\sim q(x)}\left[\log\frac{q(x)}{p(x)}\right]$$

蓝线为被近似的分布$p(x)$，红线为近似分布$q(x)$

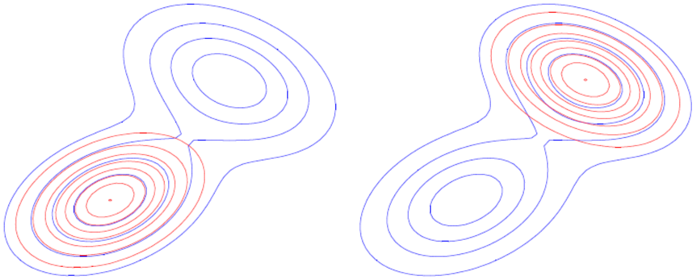

概率符号使用约定

为描述简洁，后续课程中， $P(X=x)$ 统一简写成 $p(x)$ 。根据上下文，x即可以代表某个具体样本，也可以是变量，代表任意样本。

下一讲

统计推断方法